本笔记是从上海交通大学软件学院的计算机系统基础(系统软件)整理而来，学期还没结束，还在持续更新中，文档并没有仔细校对过，很大一部分的课上的即时记录，肯定存在错误。仅供学习使用，如果侵犯任何个体或组织的权益，请联系我进行删除。

20210302

如何进行异步异常处理？
用一个特殊的硬件 interrupt controller，告诉 CPU 换一个指令流执行，类似于一个很远的 jump。
exception 发生了以后，去执行 kernel 中的代码。切换到 interrupt 对应的 exception handler 的代码。只是和当前程序无关，是被动的打断。因为无关，所以处理完了要回到当前程序的下一条指令的去执行。

异步异常包括了以下例子
1.I/O 打断
比如说在命令行中按下了 ctrl+C；网络包来了；硬盘扇区数据到了等。
2.硬重置打断（硬件关电源）
3.软重置打断（ctrl+alt+delete）
要支持程序的切换，比如说执行到一个地方做不下去了，需要等待一个信息，所以要有切换和唤醒的机制。

interrupt controller 有一根引脚连到 CPU，来通知 CPU 执行打断操作。

总线把设备连在一起。软硬件协同：硬件和软件一块去完成一件事情、上层语义（软件）来实现具体的功能(比如 page fault 如何实现复杂的逻辑，不能靠事先烧在硬件中），硬件只负责打断。

这是典型 IntelCpu 中的架构

BUS 分成几条，因为需求有不一样。因为连在 bus 上的数据的传输速度是不一样的。

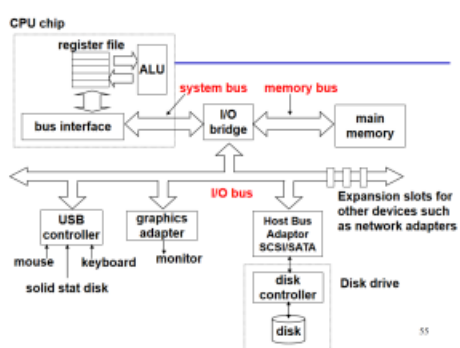

显然 system bus 会非常快，功能基本上都是把硬件连在一块。

外设和 CPU 如何通信？

CPU 直接能访问的只有内存。如何访问设备？
外设有 I/O port，把 I/O 抽象为 port 可以认为是发命令的途径，可以把命令通过 port 来发给外部设备，称为 in/out 指令，都是 driver 来使用，而不是自己写程序来执行。
I/O port 可以映射到内存中，我们所面对的内层是经过操作系统抽象的 virtual memory 的内存。所有可以映射到 I/O devices 上。然后对外设的操作就变成了内存访问。
每个设备会占用不同数量的 port，来申请对应的资源。
其中有一些和 interrupt 有关，磁盘比较慢读数据到内存里面。
CPU 可以发起指令让磁盘数据到内存中，CPU 不会傻等，需要有异步机制用之前的 interrupt 机制。
1. CPU 首先向磁盘发命令，告诉磁盘要读哪块的数据以及读到内存的哪里。
2. 磁盘可以直接往内存里写数据（比较慢），此时 CPU 不需要参与这个步骤。此时可以专门设计一个 DMA(direct memory access)直接来回读写，CPU 就可以不用管这件事情。把任务交给 DMA，CPU 干其他事情。DMA 完成 copy 任务后，可以通过 interrupt 的方式告诉 CPU 这件事情完成了。CPU 有针对这个 interrupt 的处理预案，可以从 copy 完成的内存地址去读数据了。
凡是异步的情况，都会返回到被打断的进程的下一条指令。
Interrupt 是硬件提供的一种支持。之后所有程序的 process 都是基于这个功能的。

Process 是 CPU 上执行的程序的一个单位
每个 process 自己干自己的事情，但是共享 CPU。
所以我们要介绍 context switch，完成对 CPU 的分时共享（并发）。

实际的行为是 shell 会为你创建一个 process 来为你运行一个程序，加载到对应的内存然后运行。

Process 之间不同点在于 context 不同。Context 是来作为 process 的一个当前的状态，包括占用的内存，等资源。
首先要创建一个进程，可以运行自己的程序也可以运行其他的程序。

Process 比较低级，只能通过 fork 的形式复制一个自己，但是每个进程的代码都是要写在里面的。Fork 情况比较快，copy 自己就可以了。创建别的程序的进程就还要加载内层等。我们要先搞清楚每个进程如何使用 CPU，CPU 归你这个进程的时候，就是接受指令流来执行。

最早开发的 CPU 就是实现就很简单，程序塞进去一个人用就可以了。当有多个进程的时候，有多个执行指令流，只能把不同进程的指令流 merge 在一块变成一根指令流，然后交给 CPU 去做。就可以让一个 CPU 去跑一百个进程。操作系统提供的 merge 抽象很重要，但是这是一个动态的过程，牵涉到一个 context switch。

在不同进程之间切换就代表，进程都处于 active 状态，称为并发进程（concurrency）。一个相似的名字是并行（parallel），指几个程序同时执行。并发是指生命周期重叠(overlap)。并发不一定是并行的。

Context switch 不需要切换的足够快，还有内存的条件，不同进程使用不同块的内存。上下文切换必须要有操作系统来完成，要从 user 切换到 kernel 来使用,kernel 的代码是一样的，再回到另一个程序的用户态，然后回到 kernel 里上下文切换的指令，然后回到 user 态。也就是恢复也是一层层往上恢复的。
上下文包含了 code 和 data（内存中），记录执行到哪，需要有 PC，状态寄存器,user 和 kernel 的 stack，记下这个进程中的 kernel 对应的状态。
Kernal 的代码是被所有进程共享的，kernal 中的 data 是每个进程 specific 所特有的，存储了

一些 context 中的状态。
上下文切换中，真正要 copy 的东西是很少的，内存中的东西都不会被修改，所以只要记住在哪里就可以了。一个进程切换到底切换给谁呢，都要记录在 process table 里面，。

上下文切换

把会被擦掉的主要信息来保存起来。支持多任务，多任务不是为了提升效率的。而是要让一台机器完成多个任务，让用户体验能上去，对于每个程序来说，效率是变慢的，从整个系统的角度来说，性能也是下降的，因为要做上下文切换的指令。100 条里可能 20 条是为了切换的。
一个进程获得 CPU 的连续时间，称为一个时间片。时间片到了就要切换到下一个进程，时间片就是一个切换的阶段。时间片可以手动设置，时间片越小，CPU 消耗在切换上的指令就会多。服务器时间片会比较大。时间片小意味着用户体验会更好。所以有 timer 的硬件，定时给 CPU 发中断信号。
Signal（进程之间的通信）也是基于这个的，JAVA 的 exception 也是基于这种底层实现的。
时间片切换是被动切换，block 是主动切换（eg.程序中有 read 或 sleep）。

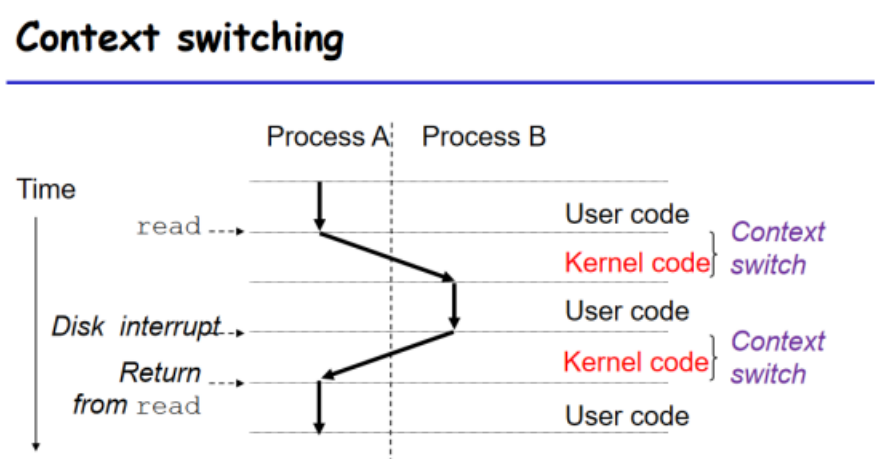

读完磁盘后，DMA 会来一个 interrupt 告诉 CPU 磁盘读完了，经过调度评估后，会回到 userA。
A->Kernel->B->Kernel->A

上下文切换有一个 scheduler，其决定下面执行谁。决定是不是剥夺当前的进程，然后执行 save 和 restore 的逻辑。Scheduler 是一个代码的集合。其对 process 是透明的，只要保证回来后能继续执行就行了。

上下文切换的代码本身是 overhead，需要尽可能快
一个进程的三种状态：
Running（可以被执行，但不一定在执行）
Stopped（blocked，没执行完，但是这时 cpu 给它也执行不下去，因为在等网络包回来或者其他耗时间的行为。）

Terminated（已经执行完了，但是还未被回收。一个进程被回收是一个过程，不是一结束就直接回收的。比如 zombie 状态，虽然 terminated，但是其遗留的信息比较重要，比如 main 的返回值）
最主要的切换在 running 和 stopped 之间，比如主动进（read），ctrl+d（debugger 把一个程序停在那边，进程受到了一个 stopped 消息）
Signal 信号：比如 ctrl+d 发出了一个 SIGSTOP 让程序停下来。
从 stopped 回到 running 状态，比如受到包的时候会向收到包的进程发一个 SIGCONT

用户主动进入 kernel 的方式只有 syscall，syscall 返回值是一个统一的整形返回值（进行了一些编码，负数代表出错，会把出错信息放在 errno 里）
任何 syscall 在调用的时候要考虑到是会出错的，比如说 malloc 是一个 syscall，但可能分配失败。Syscall 都会被打断，要检查 syscall 的返回值，要有对应的出错处理。
书中大写的都是包装过的 syscall，做过检查的。出错时要用全局变量 errno 打印错误信息

每个进程都会有一个 ID 号（进程的唯一标识），PID（大于 0）。Getppid（得到父进程的 pid）

Fork 是创建子进程的方式。是创建一个和自己完全一样的进程出来，执行一样的代码。几乎完全一样，就差了 pid 不一样。需要在一份代码里分出两块来，一块是子进程执行，一块是父进程执行，代码在两个进程中执行不同的路径。Code 和数据都有两份，初始值都一样。

Fork 的特殊行为，调用一次，返回两次。因为调用前是一个进程，调用完是两个进程。通过返回值（父进程返回子进程 ID（大于 0），子进程返回 0）可以来判断出父进程和子进程。然后两个进程可以进行协作了。两行打印的先后是不确定的，因为成为了两个进程。要看操作系统的调度策略。

0309
命令行执行的程序是控制台 fork 产生的，不是创建一个空的进程再把程序填进去，因为这样效率很低。
为了服务更多的 client，webserver 会创建很多进程，所以可以用多个进程来完成一个目的。所以 fork 接口的设计，也是为了服务这种通用的目的来实现的。创建一个和主进程一样的进程，效率会比较高。而如果创建一个空的进程，效率反而会低。fork 的返回点就是子进程执行的第一条指令，区别只有返回值不同。两个进程的虚拟地址是一样的，数据，堆，栈，完全相同。通过文件传递信息可以实现父子进程之间的交互。fork 进程的先后顺序是不确定的。文件标识符是可以共享的，而其他的东西都是复制过在分别的内存空间里。

首先介绍 reaping child process，然后再学习 console shell 控制台的行为是怎么样的。

回收子进程：换句话说自己是不能把自己回收的，进程的回收默认情况下是由父进程来回收的。进程有三种状态（1.running，2.stop 不会被调度因为它在等一些事情的发生，比如等网络包发生，或者被 gdb 停住，可以回到 running 状态。3.terminate 状态，程序已经结束了，比如在 main 函数结束了，但是并没有被马上回收，因为有些进程还对这个进程的遗言比较好奇，所以系统不会马上回收这个资源。）所以子进程如何把消息传递给父进程呢？所以进程在退出后需要主动地回收。所以 terminate 后就进入了 zombie 状态，等待父进程回收。首先需要有特定的 syscall，在这个过程中可以检查子进程的状态，比如返回值。系统保护的默

认机制。如果父进程不回收子进程，系统有 init 函数。如果有子进程的父进程退出了，其子进程会转化为 init 的子进程来进行回收。init 的 pid 是 1。kernel 创建了 init 进程，然后切换到 init 进行就切换到了用户态。

比如守护进程或者一些服务，需要运行很长时间，这些叫做 long-running 进程。对于这种进程，如果不回收子进程，又在 create 子进程，那么子进程就会越来越多，子进程打开的空间和内存就不会被回收。最终内存就会受到影响。每个系统进程和打开的文件都有上线，所以要及时回收子进程。由父进程调用 wait 或者 waitpid 来进行回收子进程。返回值是被回收掉的子进程的 pid。一次调用只会回收一个处于 zombie 子进程。waitpid 可能会停在那边，因为子进程可能还没死。确定性回收，使用 waitpid（明确的指定子进程 pid 号，如果 pid=-1，就是回收随便一个死掉的子进程，如果还没有人挂，那么也会等。）等到你挂了我就回收你。如果不存在子进程，返回-1 并设置 errno 为 ECHILD。如果主进程收到了一个 signal 中断，返回-1，设置 errno 为 EINTR。option 默认为 0，从指定的子进程去等，然后回收退出。

父进程要干自己的事情，不能让 waitpid 一直等待，所以提供了 WNOHANG 看一下，没有就干自己的事情。
status 是用来带回返回值的状态，同时通过了编码返回值更为复杂。需要用 wait.h 中定义的一些宏来检查这个 status
status 提供了一些 WIFSIGNALED 和 WIFSTOPPED 方法，来进一步得到程序的死因是什么。
waitpid 是随机一个 zombie 子进程回收，不一定是先死的那个，或者是 pid 小的那一个。
这种情况是因为并发造成的不确定性。

接下来简单的函数
sleep 和 pause 都会让进程进入 stop 状态，
可以被 signal 打断出来

execve 第一个参数:可执行文件的文件名，第二个参数:程序的参数，第三个参数：环境变量（属于系统的全局环境变量）
这个函数会把当前程序的栈什么的都擦掉，把读入的程序状态 copy 进去
所以这个操作是 load and run
这个函数，如果不出错的情况下，是不会返回的。（一次调用，返回零次）
但是也有可能发生异常会退出，比如文件不可读，文件找不到之类的。

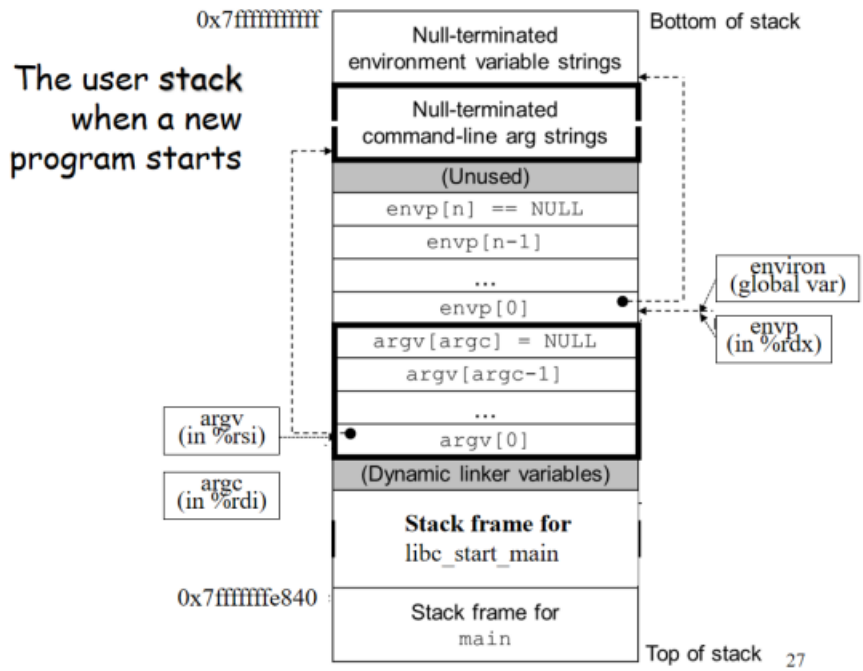

Main 函数没有提供 environment 的参数，很少情况下会使用环境变量。
我们可以通过键值对来指定一个环境变量。

```
#include <unistd.h>
char *getenv(const char *name);
                    Returns: ptr to name if exists, NULL if no match.
int setenv(const char *name, const char *newvalue,
           int overwrite);
                                Returns: 0 on success, -1 on error.
void unsetenv(const char *name);
                                                Returns: nothing.
```

怎么写自己的 shell？
当前大家使用的 shell 比较多，比如有 bash，cshell 等，都是在标准 shell 上增加新的功能。Shell 的主要功能就是来运行程序的。最简单的 shell 要做两件事情，1.从用户那里读命令 2.读一行命令，解析命令并执行。
所以要做字符串的解析，parseline，以及 bulitin_command（内置的命令，一些关键字比命令本身更优先）
Shell 的主题就是一个循环，从用户态执行一行

```
9  int main()
10 {
11   char cmdline[MAXLINE]; /* command line */
12
13   while (1) {
14     /* read */
15     printf("> ");
16     Fgets(cmdline, MAXLINE, stdin);
17     if (feof(stdin))
18       exit(0);
19
20     /* evaluate */
21     eval(cmdline);
22   }
23 }
```

feof 是解决文件输入的情况。
我们关心的更多是 eval 部分（解析+执行）

```
/* eval - evaluate a command line */
void eval(char *cmdline)
{
  char *argv[MAXARGS]; /* argv for execve() */
  char buf[MAXLINE]; /* holds modified cmd line */
  int bg; /* should the job run in bg or fg? */
  pid_t pid; /* process id */

  strcpy(buf, cmdline);
  bg = parseline(buf, argv);
  if (argv[0] == NULL)
    return; /* ignore empty lines */
```

也就是把 xxxx xxxx xxxxx xxxx 按照空格分开，放到 argument 里去。换句话说，argument 是一个指针数组，把其指向对应的参数。
Parseline 大致就是把参数之间的空格替换为结束符。

```
/* parse the cmd line and build the argv array */
int parseline(const char *cmdline, char **argv)
{
  char *delim; /* first space delimiter */
  int argc; /* number of args */
  int bg; /* background job? */

  buf[strlen(buf)-1] = ' ';
  /* replace trailing '\n' with space */
  while (*buf && (*buf == ' ')) /* ignore spaces */
    buf++;
```

把最后一个替换为空格

0316 课程笔记
运行 shell 有多种模式
一般是前台执行，等待程序执行完毕后，再回到 shell 里面，此时可以看到程序的运行结果的输出情况。不会输出多个程序同时往屏幕上打印。（同步的形式）
后台运行：在命令中最后加上&符号，和前台并发执行，生命周期会重叠。父进程会直接回到 console 执行下一行命令。
Shell 创建一个子进程，运行我们提供的二进制代码。前台运行，shell 等待子进程结束（waitpid），如果是后台运行就不需要等待。

如何实现 ctrl+c 功能终止子进程呢？
这节课介绍 signal，我们在讲中断的时候讲到了它是一个底层的机制。打断 cpu 的执行流，可以分为同步的还是异步的，有关的还是无关的，等。上层有很多基于下层硬件提供的中断机制实现的功能，都是改变程序的执行流，打断了当前的程序以后去执行其他的。比如 java 抛出 exception，程序会跳转到 exception handler 去执行。写一个正确的 signal 是很困难的。在系统中增加了 signal 机制会导致程序很复杂，但是能够改变执行流，这点很重要。所以现在通用计算机都采用了 signal 机制，单片机等小型机可能就没有这一套机制。我们主要关注的还是实现的机制，实现代码的时候需要注意什么，应用场景有很多，不在课程中介绍。

Signal 最早出现在 unix 系统，这是一个软件层去实现 exception 的方法。硬件上实现是通过引脚实现。Signal 允许一个进程去中断另一个进程，只有 kernel 能够操作这件事。一个进程想打断另一个进程或者给另一个进程发消息，会通过 kernel 以 signal 的形式去做。所以 signal 永远是 kernel 向进程发送消息的一种形式。我们知道一个进程去 kernel 需要主动地通过 syscall，而从 kernel 向进程发消息就是通过 signal，其原因有很多种比如是其他进程想发消息。

Shell 中命令 Kill -9 15213 的意思是向进程 15213 发送 9 号 signal（SIGKILL）
这个命令是发送 signal 后让进程自己去自杀掉。

Signal 分为硬件触发和软件触发。Signal 其实就是一个消息、一个数字，并不是去做什么操作，只是发了一个信号过去，至于做什么，都是由那边的进程自己完成的。这个数字不同就代表了不同的事件。硬件事件，有除零（SIGFPE）：CPU 发现不能除零，中断给操作系统，给执行这个语句的程序发送了除零操作；执行非法指令（SIGILL）；内存地址错误（SIGSEGV），也一样发现处理不好了以后发送信号给程序，然后在屏幕上打印 SIGSEGV。
软件事件，有 ctrl+c（SIGINT）把程序中断掉；SIGKILL 杀掉另一个进程；SIGCHLD 当一个子进程死亡或者停止了后，会向父进程发送 SIGCHILD。

发送 signal 分为硬件发送（黑盒，不需要管）和软件发送（向任意进程发 signal）
Alarm 机制，固定时间后向自己发送 signal。当然是有权限的一些问题。发送消息给一个进程，这个进程不一定会运行，所以更像是寄了一封信。或者每个 signal 维护了一个 bitmap，发送了只是置为了 1，需要接收的进程去主动检查。
所以这是一个异步的操作，什么时候被处理都是对面决定的。

kill（pid_t pid, int sig）函数，出错可能是因为没有权限，进程不存在等。
发生 context switch 的时候，在执行主干代码之前，会去检查当前有没有对应的 signal 去处理。也就是说正在执行自己的代码的时候，发过去会收到，但是不会处理。受到了 signal 以后会有默认行为。
默认行为分为三种处理情况
1. 直接无视，sigchild 必须要主动去修改槽函数。
2. 程序结束，进入 terminate 状态，除了终止之前打印的话不一样
3. 抓住 signal，可以写对应的 signal handler，收到了 message 后就去执行对应的 function。注册不同的自定义 signal handler。

在 shell 中 ctrl+c 先向 shell 发送 terminate 信号，然后 shell 注册了转发给前台程序的信号处理机制。

Pending 信号：收到了，但是还没有进行处理。只能 pending 一个信号。每个 signal 对应了 0 和 1，每收到一个都会直接置 1.可能已经收到了三四个，但因为都是置一，可能有一些 message 在 pending 过程中被丢掉了。所以不是收到了一个 message，而是有 message。

检查 Bitmap 的时候，发现可能收到了很多个 signal，会依次执行多个 signal 处理。

同样还有一种 blocking，我当前在做一些很重要的事情，不想被你打扰，此时可以关闭消息的接收。如果设置了 block，message 不会消失，只是不去执行它。不过 block 不是全局的，是对于每个 signal 的 01，所以也是个 bitmap。可以关闭一部分 signal 的接受。Message 依旧会被投递，只是不调用处理函数。所以当 block 恢复的时候，依旧会处理积压的 signal。

跟 signal 相关的 kernal 里会维护 pending bitvector 和 block bitvector。当有人发送了一个 signal，就会设置 pending 的一个位。调用 signal handler 后，bit 位会被清理掉。

我们具体地看一下 sending 和 receive

我们先要引入 process groups，在命令行执行的时候，一般是执行一个二进制程序然后加上一个参数。但是一个复杂的命令可能会包含多个二进制程序，比如前一个程序是后一个程序的输入，运行了多个子进程，其间还有信息的传递。一条命令其实就是一个前台的任务，一个任务可能有多个进程。当运行一条命令就创建了一个进程组，通常情况下只有一个进程，做复杂操作的时候，就会有多个进程。有一个进程组 ID，通常是第一个小的进程的 ID。SIGNAL 是以进程组为对象发送的，可以发给一个组或者组里的特定的一个进程。Setpgid 可以把某个进程设置到某个进程组里面。
对于一个复杂命令创建多个进程得到 pid，然后设置其在一个进程组中。
Eg: setpgid（0,0）把自己设置进自己的进程组号里面。

创建前台 job 组，其代表进程。
Pipe 是进程之间通讯的方法，是一种 syscall。
前台只有一个任务（job）或者称为前台只有一个进程组。

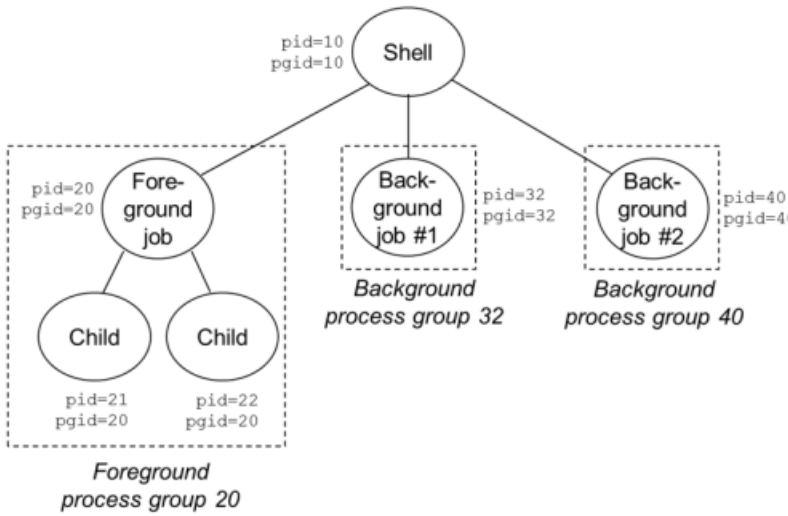

25

再回顾一下，按了 ctrl+c以后，硬件中断发送 sigint 发送给 shell，shell 转发信号，找到前台的任务对每一个进程发送相同的消息。
Ctrl+z是让进程 stop

如果 kill 参数小于 0，是向进程组发送。进程号的获取需要通过一些额外的机制，比如需要注册，或者通过 killall 函数等。
Pause（）就是停在那里等待一个消息被打断。

```
1  #include "csapp.h"
2
3  int main()
4  {
5    pid_t pid;
6
7    /* child sleeps until SIGKILL signal received */
8    if ((pid = Fork()) == 0) {
9      Pause(); /* wait for a signal to arrive */
10     printf("control should never reach here!\n");
11     exit(0);
12   }
13
14   /* parent sends a SIGKILL signal to a child */
15   Kill(pid, SIGKILL);
16   exit(0);
17 }
```

子进程先被调用：Pause 后收到一个 sigkill 直接退出，就不会
父进程先被调用：子进程已经被创建了，message 依旧会发送成功。子进程执行 pause 之前会检查 bitmap，然后发现接收到了 sigkill 直接退出。
系统里面两个信号是不能被修改的，其中包括 SIGKILL。

Alarm 调用 SIGALARM，自己给自己设置一个闹钟发送，过一段时间就会收到一个 SIGALARM，需要自己设置信号槽函数。整个系统里面只有一个 alarm，新设置的闹钟会把之前设置的还没响的闹钟覆盖掉。

Context switch 到你这个程序之前，查看 signal，如果有就回到用户态执行 signal 的代码。

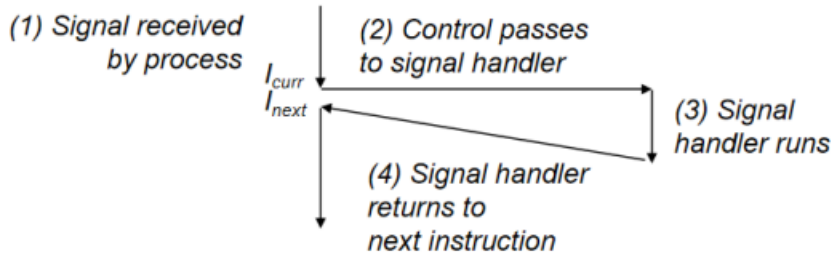

并发执行流。
Signal handler 如果代码很长，在执行过程中也会发生 context switch，回来的时候可能会发生新的 signal handler，会有一层层嵌套。

调用 signal 的情况下需要满足两个条件：
1. 收到了 signal
2. 没有被 blocked 掉
如果发现了 signal 是个空集合了，就回到了原来的 main 函数控制流

有些信号会终止进程和 dump core（内存映射存到硬盘便于 debug）

SIGCHILD，
不要太傻地去回收子进程，之前我们的方法是定期 waitpid 立即返回，事实上我们可以在 sigchild handler 中去回收子进程。

我们可以通过 syscall signal 去注册 handler。不能覆盖 sigstop 和 sigkill。

```
#include <signal.h>
typedef void handler_t(int)
handler_t *signal(int signum, handler_t *handler)
                          returns: ptr to previous handler if OK,
                          SIG_ERR on error (does not set errno)
```

返回值是原来的 handler，参数是新的 handler。

- Three ways to change default actions:
  - If **handler** is SIG_IGN, then signals of type **signum** are ignored.
  - If **handler** is SIG_DFL, then the action for signals of type **signum** reverts to the default action.
  - Otherwise, change action to **handler** (called signal handler)

有三个宏，设置为 ignore，恢复成默认值，或者提供一个 handler。Handler 只能接受一个 int，所以可以用一个 handler 为多个 signal 服务，通过判断输入参数的 signal 号。

这个函数是功能是注册安装一个 signal handler，操作系统会帮你调用这个 handler。

```
1  #include "csapp.h"
2
3  void handler(int sig) /* SIGINT handler */
4  {
5    printf("Caught SIGINT\n");
6    exit(0);
7  }
8
9  int main()
10 {
11   /* Install the SIGINT handler */
12   if (signal(SIGINT, handler) == SIG_ERR)
13     unix_error("signal error");
14
15   pause(); /* wait for the receipt of a signal */
16
17   exit(0);
18 }
```

注意这里是 exit(0)会终止整个程序。在准备截获之前安装上自己的 handler。正常情况下处理完调用 return 回到原来的执行流。

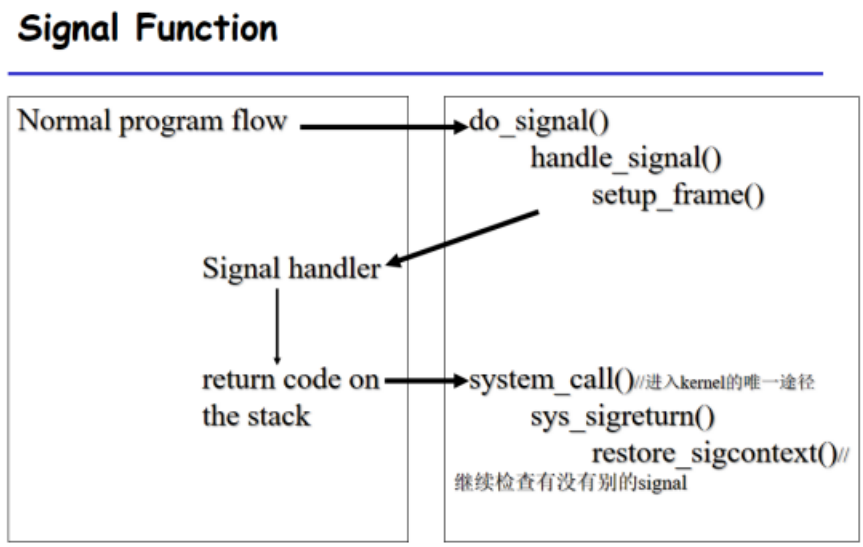

Signal handler 完成回到 kernel 态后，需要继续检查 signal 情况。

在执行信号 10 的处理中，信号 10 会被阻塞，以免递归地调用同一个 signal。因为执行的是同一份 signal handler。****如果一个 handler 处理多种情况，如果有多个信号同时打断，是设置多个信号的 block 吗？ 答案：不是，只设置了第一次信号的 block。所以在编写 signal handler 的时候要尽可能避免这种情况，这是异步不安全的。

Signal Handlers can be interrupted

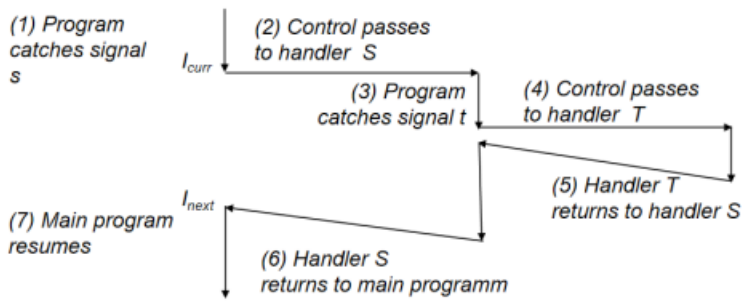

$s \neq t$

此时存在三条并发的执行流，可能会出现各种可能的问题。

存在一个操作系统帮助 block 的情况，处理 K 的情况 K 会被 block 住。显式地 block:使用 sigprocmask 及其一些帮助函数。

Blocking and Unblocking Signals

```
#include <signal.h>

int  sigprocmask(int how, const sigset_t *set,
                 sigset_t *oldset)
int  sigemptyset(sigset_t *set) ;
int  sigfillset(sigset_t *set);
int  sigaddset(sigset_t *set, int signum);
int  sigdelset(sigset_t *set, int signum);
                      Return: 0 if OK, -1 on error
Int  sigismember(const sigset_t *set, int signum);
        Returns: 1 if member, 0 if not, -1 on error
```

最简单的是用现在的 set 和原来的 set 做一个 and 或者 or 操作。

Explicitly Blocking Signals

- sigprocmask
  - Changes the set of currently blocked signals
  - SIG_BLOCK: add the signals in set to blocked (blocked = blocked | set)
  - SIG_UNBLOCK: Remove the signals in set from blocked (blocked = blocked & ~set)
  - SIG_SETMASK: blocked = set
  - If oldset is non-NULL, the previous value of the blocked bit vector is stored in oldset

要 set 第九个信号，那就是搞一个 00000100000 的和原来的 set 做一个 or 操作，其余同理。

2021/3/23

signal 是进程之间的通信方式，是反向地从 kernel 向用户态发送信息的机制（异步，并不是马上得到处理，只有进入一个 cycle 在执行 main 之前才会调用）。正向只有 syscall（同步）。这节课我们关注怎么写一个 signal handler，写对并不容易，很容易造成并发问题。Main 执行流和 handler 生命周期会重叠，而且很长的情况下不知道什么时候被打断，包括还有递归打断的情况。这会带来一种特殊的 concurrent bug，处理、解决、发现都依赖于特定的执行情况，这些都由 kernel 来决定、不受控制，很 tricky。（Eg：打断的点不同，出现嵌套的情况不一样。）这些错误在 debug 过程中很难被复现。

书给出了写 signal handler 的 guideline。

G0:尽量保证 handler 简单，让 handler 的执行时间执行时间越短（降低嵌套的可能性，把指令留到 main 函数来执行，降低 overlap 的程度。）比如在 signal handler 里面只设置一些 flag（作为一种通知的机制），在 main 函数里来完成任务，但是这会是 main 函数要周期性地检查对应的 handler。

G1:这条影响比较大，要在 handler 里面调用函数是异步安全的（asyn-signal-safe）。必须要选取这些 safe 的函数来使用，比如说 printf springf malloc exit 是不安全的。Bug 不一定会发生，但是存在这些 bug。为什么会出错？因为这些函数会尝试去拿一些锁。如果在 main 函数里面也要使用相同的屏幕的锁。如果 handler 里的 printf 尝试去拿锁，但是锁在 main 函数里被拿着，这种情况下程序会进入死锁状态。锁：只有一个人可以进去，来保证进程里的代码是安全的，只被一个人访问。Signal handler 也要实现成 safe 的。Safe 函数有一个专门的

Safe I/O Package

```
#include <csapp.h>
ssize_t sio_putl(long v);
ssize_t sio_puts(char s[]);
                Returns: number of bytes transferred if OK, -1 on error
void sio_error(long v);
                                                Returns: nothing
```

列表。 • _exit is an asyn_signal_safe variant of exit

打印函数，不支持格式化输出。直接调用 syscall 来打印。

G2:保存和恢复 errno。errno（error number）是一个全局变量，是调用的库里定义的全局变量。当调用函数出错的时候，error number 会被设置。为什么要特意保存和恢复 error。在调用 syscall 的时候如果需要做一串耗时很长的指令，期间过程中会发生 context switch。最新一次 syscall 的 errornumber 会把 main 函数里面 syscall 的 errornumber 覆盖掉。会出现 errno 覆盖的情况，但是 errno 是不希望被覆盖掉的。这个和我们使用寄存器一样。参考 callee-save 和 caller-save，一般如下进行 errno 的保存。

```
1  #include "csapp.h"
2
3  void handler1(int sig)
4  {
5      int olderrno = errno; //保存外部使用时记录的errno
6
7      if ((pid = waitpid(-1, NULL, 0)) < 0)
8          sio_error("waitpid error");
9      sio_puts("Handler reaped child %d\n");
10     sleep(1);
11     errno = olderrno ;
12 }
13
```

问题:回收子进程回收不干净。
原因：signal 不会 queue，当处理 signal 的时候，signal 被 pending。如果同时来了两个 signal 不能区分出来。
每次调用的结果可能不同。所以应该在 handler 里面循环地调用 waitpid 回收子进程。

关于 signal handler 的行为的，可移植性（最低要求是用户那里可以执行）问题。
对于 signal handler 我们也希望其在类似的平台下能够处理。不同系统和版本下对于 signal 的语义约定可能有些差别。
1. syscall（可能发生上下文切换，执行时间比较长）被 signal 打断的时候怎么处理。程序接到 signal 是比较频繁的。为了设计上的简洁，我们直接 abort 掉。凡是有 signal 过来了，syscall 就直接 abort 掉，不管谁打断我都停下来，由上层来决定下一步行为是什么。Linux 的默认行为是如果 syscall 被 signal 打断了，就会重新尝试（retry）。Retry 属于 semantic，在不同操作系统下的行为可能不同，需要有意识地对 syscall 进行处理。
处理分两种 1.自己对情况进行检查处理 2.自己设置好 retry 这种情况。
2. 在执行 k 这个 signal handler 的时候，可能被其他 signal 打断，不会被自己打断（把自己的 signal block 住）。避免自己调用自己的函数，出现重入的问题。因为如果这个函数访问了全局变量，那么再进去会重写，包括说这个函数中调用了锁的情况。但是这个行为也是可以配置的，系统的默认行为可能不同，换一个场景下代码就可能出错。

sigaction Function

```
#include <signal.h>
int sigaction(int signum,
              struct sigaction *act,
              struct sigaction *oldact);
                       returns: 0 if OK, -1 on error

struct sigaction {
  void (*sa_handler)();       /* addr of signal
handler,
                                 or SIG_IGN, or SIG_DFL */
  sigset_t sa_mask; /* additional signals to block */
  int sa_flags;                /* signal options */
} ;
```

可以控制 handler 的行为，提供了一个数据结构，其包括 handler，handler 的 mask 和 flag 其中有很多 bit 位。

```
/* block sigs of type being handled */
sigemptyset(&action.sa_mask);
/* restart syscalls if possible */
action.sa_flags = SA_RESTART;
```

系统会帮你 restart，linux 会默认帮你置上。

无视 signal

- Once the signal handler is installed, it remains installed until Signal is called with a handler argument of either SIG_IGN or SIG_DEF

一些 concurrency bug

G3:处理共用全局变量或结构时，需要 block 对应的 signal
如果在 addjob 里发生了 context switch，比如说链表刚刚要开始执行加元素操作加了一半时，要被删除元素操作打断。使用的过程中会被打断，会出现错误。

```
32        Sigprocmask(SIG_BLOCK, &mask_all, &prev_all);
33        addjob(pid) ; /* Add the child to the job list */
34        Sigprocmask(SIG_SETMASK, &prev_all, NULL);
```

所以 main 函数里和 handler 里要加上对应的 block 行为，以防冲突。Block 所有 signal，然后处理完后恢复。
但是代码还不是正确的情况，如果主进程在 fork 之后，addjob 之前被打断，会怎么样？Signal handler 会先执行 deletejob 根据 deletejob 的逻辑实现不同，可能出现 bug。比如 handler delete 完，再执行了 addjob 永久加入了一个死掉的进程。

如何写一个正确的代码？

```
29      while(1) {                                          Block SIGCHLD
30          Sigprocmask(SIG_BLOCK, &mask_one, &prev_one)/*
31          if ((pid = Fork()) == 0) { /*Child process */
32              Sigprocmask(SIG_SETMASK, &prev_one, NULL);
33              Execve("/bin/ls", argv, NULL);    Unblock SIGCHLD
34          }
```

30 行先 Block 住 sigchild，保证在 addjob 之前都不会调用 handler 去 delete。再去 fork。Fork 出来的子进程也是被 block 住的，
32 行需要恢复原始的 sigmask,因为我们要去执行 execve,不能在 mask 变掉的情况去 execve，否则行为会变化。

```
            /* parent process */
35          Sigprocmask(SIG_BLOCK, &mask_all, NULL);
36          addjob(pid) ; /* Add the child to the job list */
37          Sigprocmask(SIG_SETMASK, &prev_one, NULL);
38      }
38      exit(0)
40  }
```

第 35 行是为了防止在 add 过程中被 delete 打断的情况。
然后 37 行一起恢复。等 ADDjob 完成后，才能去进 handler 里去回收子进程。

G4 声明全局变量时一定要声明为 volatile（你这个对象是不会放到寄存器里的，每次读都会从内存中读），显式防止寄存器优化。
如果放到寄存器中，handler 会分别操作寄存器，可能会出错。
如果 Main 去读寄存器，而全局变量中在 handler 去写。Compiler 会发现 main 函数一直在读没有去写，可能会一直读寄存器。本质就是一个变量可能出现在多个地方，在寄存器或者在内存里。一个程序是不会有这种问题的。但是现在两个地方都在访问这个变量，各管各的。

汇编生成的所有 volatile 都从内存中读写这个对象。两边就能访问到正确的对象。

G5 需要声明 flag 来用 sig_atomic_t 对于这个对象的读写操作是不会被打断的。在 C 语言的一句命令，在汇编中可能是多条指令，可能被打断。两次++可能只是从 2 变成了 3.

```
while (!pid)
        ;
```

忙等，一直在 check cpu，cpu 拉满了，浪费 cpu。让 child 还没来的时候，休息休息。

我们可以用 pause 先挂起，解放 CPU 资源。但是我们 pause 可能被别的打断，所以容易被别的打断，还是要 check。但是这段代码是会有竞争的（data race）。如果在 while 和 pause 发生了 context switch，处理完就 sigchile 再也不会来了，中间被钻了空子，容易永久 pause。

我们可以使用 sleep1 来周期性检查。这是一种折中的方案。

我们希望检查和 pause 变成一个原子操作，有个特定的函数叫做 sigsuspend（mask）

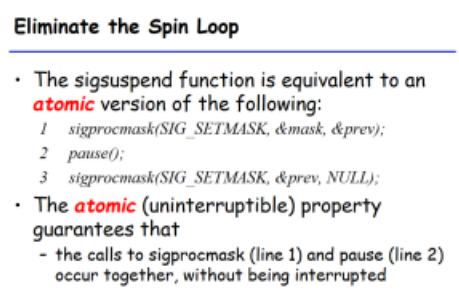

其相当于这三句话，并且这三句话不会被打断。12 代表打开中断立马进 pause。如果在 1 之前来，中断还没有打开，所以不会处理。2 的时候来了就可以 check pid 有没有问题。

```
pid = 0;
while (!pid)
  sigsuspend(&prev);
```

12 之间不会被上下文切换掉，不会被插队。
3 代表把中断再关掉。检查一下是什么打断了，如果不是 SIGCHILD，就再次进下一次循环。
包括 lock 也会导致这种东西。

0330
for 循环和 if 都是用 jump 实现的。
c 语言最多就是跳出循环跳出 switch。
从功能上，汇编可以支持 non local jump，像 c 和 java 中的 exception，从汇编层面实现很容易。但执行过程中是维护了一个栈的，call 了一个函数出来的时候栈也得是空的。如果从一个函数直接跳到另一个，栈的环境可能就不一样了，可能栈就直接乱了。所以，nonlocal jump 难在要恢复这个状态。

Nonlocaljump 需要分成两个步骤，功能就是在两个函数之间发生跳转。提供了 user 级提供了统一的异常控制流。
Setjmp 函数，是设置传送门，变量是当时栈情况（记录下开启传送门时栈的状态）。可以设置多个传送门变量，然后选取门去跳。

Longjmp 就跳走了，所以 retval 返回到了 setjmp 函数

还有 sigsetjmp 可以从 signal 中跳转到 main 函数的其他地方。要保存一个 sigmask 的信息。

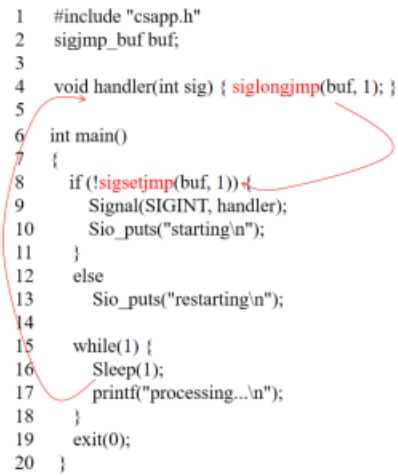

```
1   #include "csapp.h"
2   sigjmp_buf buf;
3
4   void handler(int sig) { siglongjmp(buf, 1); }
5
6   int main()
7   {
8     if (!sigsetjmp(buf, 1)) {
9       Signal(SIGINT, handler);
10      Sio_puts("starting\n");
11    }
12    else
13      Sio_puts("restarting\n");
14
15    while(1) {
16      Sleep(1);
17      printf("processing...\n");
18    }
19    exit(0);
20  }
```

进程就讲完了，可以写一些多进程合作的进程。学会了 GUI 和 console。可以通过 signal 传递信息。调度是不确定的。Signal 是一个并发的执行过程。有一些特殊的 bug 就可以理解了。

System-level I/O

三大抽象:进程、内存、I/O

I/O 就是输入输出设备，除了内存、主板基本上都是输入输出设备。从 CPU 来讲输入输出设备，键盘是输入，屏幕是输出。我们要介绍 system level I/O。Printf 知道是打印。如果一个程序没有输入输出，跑完了没结果。没有输入输出机器就没有用了。把所有输入输出设备抽象为文件。默认打开的文件：屏幕和键盘。所谓的系统级的 IO 就是一些低层级的 IO。要和硬件打交道，就必须要通过操作系统。

为什么要底层的 IO，IO 分成标准 IO（高层级的用户级 IO）、UnixIO（由 kernel 直接提供，在 syscall 上直接进行处理）。IO 可以更好地理解进程。不同的进程使用 IO 的样子是怎么样的？Eg.进程打开 IO，fork 了以后去打开 IO 呢？打开两次呢？

UnixIO 是把 IO 抽象成了文件。把所有外接设备的交互过程作为字符串。输入就是接受一个 byte，输出就是写一串 byte。在 IO 设备上，最重要的就是 read 和 write 这个 syscall。包括网络、磁盘、终端设备都是用这个。

文件会分成不同的类型。有 regular 文件，普通的文本文件。Text file：可以用 asc2 码编码。Binary file：二进制文件。

除了 regular 之外还有很多其他的文件类型。里面有一些 abcd，也有一些不可见的字符。以 byte 读出来的时候是可以读到这些特殊字符的。比如回车\n。所有文件都可以抽象为一个 byte 流。

还有其他的文件:目录文件，里面是一系列的链接，可以通过操作系统解释成文件的指针。目录会自带两个创建时生成的 link。一个点代表当前目录。两个点代表上级目录的 link。

Mkdir、ls、rmdir 都是可执行文件，是前人写好的东西。这些都属于 IO 相关的编程。

Linux 对于下面的磁盘采用了树形的结构。一个磁盘让用户直接去访问太复杂了，所以需要有一个抽象。把磁盘抽象成文件进行管理，叫做文件系统。根节点在 linux 下是斜杠。

下面就是一层层的目录用/分割。

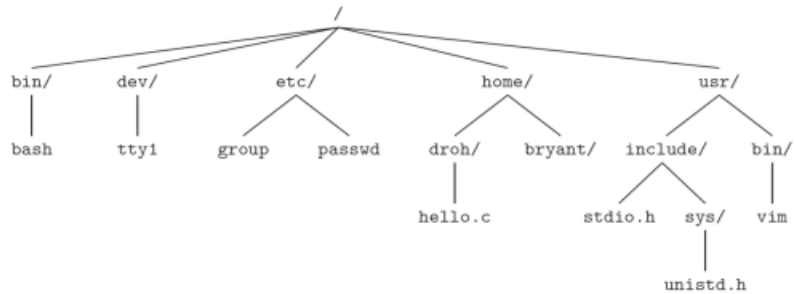

所有的 IO 设备也在 dev 设备下面。所以文件系统包括了磁盘上存在的文件，以及硬件。还包括了一些 pipe。可以用一个管道把前一个文件的输出作为后一个文件的输入。管道可以把进程之间打通。Symbolic links 就是快捷连接文件。还有一些字符和 block devices，这就是外设。

Cd 可以改变当前的工作目录。每一个进程在其之中就可以改变工作目录。

- *relative pathname: ./hello.c, ../home/droh/hello.c*
  (if /home/bryant is the current working directory)

比如要执行当前目录下的 cd 文件，如果没有点就回去找系统中的可执行文件。可以需要加./cd

这些 IO 设备在操作之前都有一个准备阶段。Printf 下一次打印是跟在上一条打印后面的，一般是相对位置的操作。这些相对位置信息都是要记录在 kernel 里面的。内核会为每一次打开文件建立特别的数据结构。一般情况下，io 设备都有 open 和 close 操作。Open 之后会返回一个标识，分为一个 file descriptor（文件描述符）。 文件退出的时候是不会马上关闭的，只有回收的时候会收回这个资源。文件描述符是 link 中数组的一个下标，存了一个 link。Fd 维护了文件的当前的位置（上次读完的位置，fileposition）、文件大小、文件使用人等。我们需要了解的就是内核为每个进程维护的这一套信息。

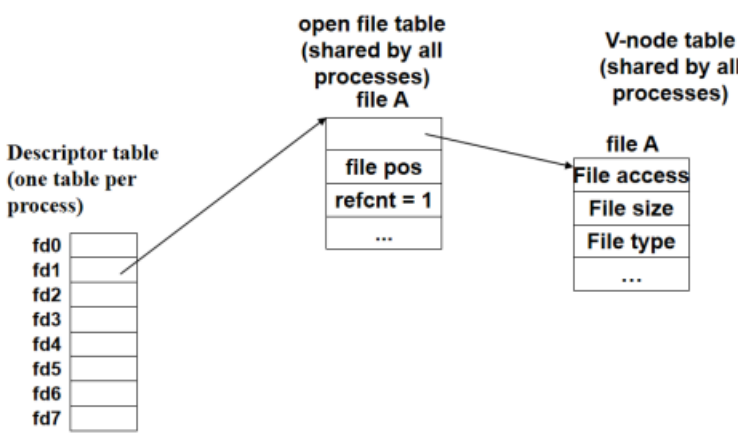

由三个部分组成。左边是每个进程都有一个 descriptor table。每个文件打开以后都会填入一

个 fd。打开一个文件时，就是用 fd 指向这个文件信息。为了避免 descriptor table 很大，会找到一个最小的 fd。指向的就是 open file table，这由多个进程共享的。比如实现进程之间的信息传递，把两个进程联系在一块。这个 table 里面记录的就是这次打开相关的信息，一个是 position，第二个是 reference count（这是用来计数的，当没有人使用的时候要回收掉）但是因为会被进程共享，所以造成这个 file 创建的进程和造成其回收的进程可能不是同一个进程。当 refcnt 为 0 的时候，就可以回收这个资源了。
Vnode table 是一个静态的信息，在文件创建的时候就有了。进程哪怕关掉了文件还会存在。File table 可以被共享，更多情况下是每个进程自己创建。

Seek 是一个 syscall，就是调整当前文件的 file pos。（seek current file position）
Open 函数有三个参数，第一个是文件名可以是绝对路径可以是相对路径。返回-1 失败，返回>=0 成功。
Flag 是只读、只写、读写打开（唯一）。还有三个可选项，O_CREAT，创建文件。Trunc 覆盖文件。Append 就是追加到文件的最后。
Mode 参数是模式，当创建文件的时候使用模式。Mode 777 就是所有权限都有。Mode 分为读、写、执行。分为 user（普通人）、group（组）、other（其他人）。Eg 777，664.

一个文件会打开标准输入输出和出错。所以第一个打开文件的 fd 应该是 3。如果没有自己关闭，进程回收的时候会关闭 fd。一个文件 close 两次也会报错。

文件有一个文件尾。Read 是外设读到内存的操作。需要有标志告诉你读完了，所以需要文件尾，这是逻辑上的，文件里是没有的。只是在 pos 到最后的时候，read 返回 0，代表只能读到 0 的 byte。

```
#include <unistd.h>

ssize_t read(int fd, void *buf, size_t count);
                    returns: number of bytes read if OK,
                                    0 on EOF, -1 on error

ssize_t write(int fd, const void *buf, size_t count);
                  returns: number of bytes written if OK,
                                              -1 on error
```

Buf 是实现分配的地址，如果分配小了就有可能出现 segmentation fault。Read 返回 0 读到了的文件尾，返回-1 是出错了。

Write 中，写进去的数据先放到 buf 里面。然后 count 写进去的数量。

Reading and Writing Files

```
1  #include "csapp.h"
2
3  int main(void)
4  {
5      char c;
6
7      /* copy stdin to stdout, one byte at a time */
8      while(Read(STDIN_FILENO, &c, 1) != 0)
9            Write(STDOUT_FILENO, &c, 1);
10     exit(0);
11 }
```

STDIN_FILENO(0), STDOUT_FILENO(1), STDERR_FILENO(2)

键盘上敲一个，屏幕上输出一个。但是键盘上敲不出 EOF，所以可能需要 ctrl+c。

Ssize_t 是有符号的 int，size_t 是无符号 int。如果 read 和 write 读了特别大的数，可能是出现一些问题。Short count 问题，即 count < 返回值。比如说 read 读到了 EOF，或者 syscall 打断了 read，导致读了一半。读到的数量小于预期的数量，这就叫做 short count。

还有 stat 函数和 fstat 函数，访问的是文件的 vnode。所以 stat 通过路径去访问文件的 vnode，可以不需要打开。在打开 fd 的情况下，可以通过 fstat 去读信息。

要访问 stat 的时候一定要通过 unixio 来做。

S_ISREG 可以检查文件的模式。

```
int main(int argc, char **argv)
{
    struct stat stat ;
    char *type, *readok ;
    Stat(argv[1], &stat) ;
    if (S_ISREG(stat.st_mode)) /* Determine file type */
        type = "regular" ;
    else if (S_ISDIR(stat.st_mode))
        type = "directory" ;
    else
        type = "other" ;

    if ((stat.mode & S_IRUSR)) /* check read access */
        readok = "yes";
    else
        readok = "no";

    printf("type: %s, read: %s\n", type, readok) ;
    exit(0) ;
}
```

S_ISREG() Is this a regular file?
S_ISDIR() Is this a directory file?

其包含了访问控制权限。

Read Directory Contents

```
struct dirent {
  ino_t d_ino; /*inode number*/
  char  d_name[256]; /*file name */
}
```

```
#include <sys/types.h>
#include <dirent.h>
DIR *opendir(const char *filename);
     returns: pointer to handle if OK, NULL on error
struct dirent *readdir(DIR *dirp);
     returns: pointer to next directory entry if OK,
                    NULL if no more entry or error
int closedir(DIR *dirp);
                     returns: 0 if OK, -1 on error
```

以上打开目录，可以一次一次地读出其包含的文件信息。可以用 while 来判空。

一个文件打开两次会怎样？

```
#include "csapp.h"

int main()
{
      int fd1, fd2;
      char c;

      fd1 = open("foobar.txt", O_RDONLY, 0) ;
      fd2 = open("foobar.txt", O_RDONLY, 0) ;
      read(fd1, &c, 1) ;
      read(fd2, &c, 1) ;
      printf("c = %c\n", c) ;
      exit(0)
}
```

foobar.txt

```
foobar
```

输出 f 的话，说明有两个 open file。输入 o 的话，说明有一个 open file 被两个 fd 共享。

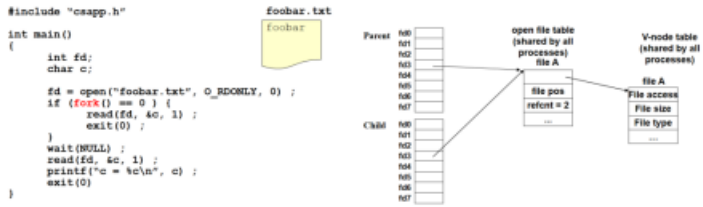

Fork 出来的 descriptor table 和原来的一样。Kernel 是会帮你 copy 一份 open file 还是帮你共享一份呢？事实上创建子进程的时候，open file table 是共享同一个 open file 的。这提供了一种途径让进程之间进行共享。Kernel 维护一个 Refcnt++罢了。

Redirect 重定向文件的输出。Shell 在创建 ls 的时候，把标准输出的文件 fd 改成 foo.txt。往 fd1 写的时候，就写到 foo.txt 里去了。所以 shell 只需要重定向，而 ls 的代码就写到 fd1 里去，不需要进行任何修改。在做 shell lab 的时候，要实现重定向就要写 dup2 函数。

0406 ics 系统软件笔记

今天会把 io 部分结束，上节课介绍了操作系统如何支持 io 的，维护一些数据结构来提供给上层的程序。一个是 fb，一种索引在数据结构中找到当前打开的位置。最主要的是，一个是一个 array，指向 file 对应的信息，第三层的一些物理上的文件。我们还介绍了一些 syscall，底层的操作系统支持的 io 系统。是读和写、打开和关闭，加上 status 函数，就可以知道文件所有的信息了。但是这比较麻烦，处于 syscall 之上比较底层。这不是我们直接使用的 io。我们经常使用的是 std io。

这节课我们介绍 robust io 和 standard io，它在 unix io 之上去构建。

首先 rio，所谓 robust 就是功能更多，在一些特点上比如性能上会有一些特点。最多的情况下会被使用在网络里。因为普通的程序基本上使用 std io 即可。但是终端设备和网络上不能使用 std io 直接进行使用的。syscall 过长可能被 signal 打断的问题（short count 问题，写的比预想的要少。），需要自己去解决。rio 分为 unbuffered 和 buffered。也就是有没有缓冲区。屏幕打印和 gpu 也有对应的缓冲区，可以理解为是一段内存。我们需要回答用 buffer 能解决什么问题。

rio_readn 和 rio_writen 是无缓冲区的 buffer。接口和原来的 syscall 基本上一样，尽可能地读 count 个字节。完成以下逻辑：

·如果出错了，那就返回。

·如果 read 被中断打断了，会帮你完成一个重试。

·如果读到的数据少了，也会帮你去重试。

·如果读到了文件的 eof，这种情况下会 break 出循环，正常的进行返回。

对于 rio_writen 的情况，就比较容易，如果被打断了也会重试。

rio_readlineb 和 rio_readnb 是读一行，如果一个个读 byte，每个 byte 从硬盘去读，会非常慢。这时候我们就使用 batch 的思想，一次读多一点。如果我们读的超过了一行该怎么办？有的地方可以退回去。但是网络包该怎么退回去？

接下来，我们介绍缓冲区 Io,在直接做一个操作的时候，缓冲区进行一个介入，因为原来的操作太慢。分为读缓冲和写缓冲。真实的读和读操作的触发不是完全匹配的，我们比如说先读 1024 个 byte 读到缓冲区里。换句话说，增加了一些内存的开销，来避免多次读写硬

盘。一个 buffer 里面的数据可能分为几块，每次读不一定把 buffer 填满（比如磁盘中已经没有数据了）读上来的数据可以分为应用已经读的，和应用程序还没有读的。这里我们维护了 buffer 层的数据结构。第一个参数是 fd，对应被打开的文件。有 cnt（还没有被读的）、pointer（buffer 中的 position）、数组（buffer 内存）。

如何来使用呢？我们要了解 buffer 和 disk 中的数据的对应关系。buffer 就等于是文件中的一个子区间，是文件最新填充到 buffer 中的数据，存在内存里面，当然 disk 上也有一份。应用程序不和 disk 打交道，直接访问缓冲区。

初始化的时候，fd 作为参数传进来，返回这个初始化完成的数据结构。pointer 指向开头，cnt 为 0.

这个 rio_readline 函数功能不太好实现，极端情况下可能这一行比 buffer 还长。首先我们要实现一个 rio_read 函数。

readline

这个代码先判断 buffer 是否已经空了，只要 buffer 不空就会判断以下情况：

·想读的比 buffer 大，直接返回整个 buffer。

·想读的比 buffer 小，返回对应的值。

然后把 buffer 中的数据 copy 到应用程序中的内存中。

然后调整 pointer 和 rio_cnt（buffer 中剩余的数量）

如果 buffer 为空，从 disc 中读取 buffer size 的数据。

·如果出错，返回-1

·如果被中断了，重试尝试读 buffer。

·如果读上来的是 0，代表读到文件尾，返回 0.

然后需要条件 pointer 到开头，以及 cnt 要设置为新填入的数据数量。

所以 read 提供了从 buffer 中尽可能读对应的数据到应用程序的内存中。

rio_readnb

rio_readnb 就是使用 buffer 的读 n 个数字，就是调用 rio_read。调用 syscall 的次数比起非 buffer 可能要少一些。

rio_readlineb

然后我们再来讨论 rio_readlineb。如果用 syscall 提供的 read，性能就很差。现在我们换成了 rio_read，这样就很快了。只要在循环中判断一个是否读到了\n，多读出来的数据被放到了 buffer 里面，便于做下一步的操作。

standard io 是一种 high level 的 io，对于 std io。暴露出来的接口用 f 开头，比如 fopen fclose。其同时实现了读和写的缓冲。里面最重要的概念就是，stream 的抽象。在文件的基础上抽象出了 stream 的概念。流就像水一样，一去不复返。如果采用了这一套接口，就不太会返回到读过之前的东西。所以网络更适合的抽象应该是流。

缓冲区对功能是有限制的，比如读上缓冲区以后，如果是网络就不能再丢回文件中。

前面讲了 std io 很重要一点提供了完整缓冲区的功能。写操作会等凑够一定的数量才会写到 disc 中。如果 printf 如果没有\n 是不会写到缓冲区中的，\n 就是缓冲区的一个刷新条件，还有定时刷新，还有一种强制刷新，也就是 fflush 来保证执行到当前位置之前的写操作都会在磁盘上生效。

之前介绍的 rio 和 std io 是建立在 unix io 之上的，当然应用程序可以直接调用 unix io 和 syscall 去做。那么应用程序在什么时候应该选取哪种 io？一般情况下，是不推荐应用程序混合使用不同种 io 的。如果混用有 buffer 和无 buffer 的情况，可能会导致直接读到 buffer 缓冲后的位置。

unix io 的利弊

这是最 general 的，所有功能都可以完成。是 low level 的，理论上单次 io 操作，overhead 是最小的。其余 io package 是实现在其之上的。 metadata 是只有 unix io 提供了检查接口。（fstatus 不属于 std io，属于 unix io）

unix 是异步安全的，在 sial 啊了 handler 里面只能使用 unix io。

实现很脆弱很敏感，容易操作应用程序代码复杂，容易出错。应用程序写出的代码可靠性低于 std io。

std io 的利弊

支持缓冲区，在一系列操作的时候性能更好。支持 general 的操作。比如支持变参数的函数（printf）

不是 signal-safe 的，不能访问 metadata。因为加了缓冲，不太适合网络的操作。

我们介绍几个和 strem 有关的。read buffer 和 write buffer 是两个 buffer。stream 又读又写的情况，如果写缓冲区没有刷新的情况，跟了一个读该怎么办？可能会读到即将被覆盖的旧数据，所以建议不要这么做。如果一定要跟在后面，需要加上 fflush。包括还有一些 eof 的处理。

如果我们为了在一个网络流上同时进行读写。我们需要把这个网络流打开两次，会出现新的问题。把 fd 打开两次，有两个数据结构，当我们 close 的时候，可能会把一个文件 close 两次。所以在流上处理一些行为的时候，是非常 tricky 的。

综上所属，std io 上不适合处理网络的情况的。

一个 general 的规则：尽可能使用 high-level 的 io。但是遇到 signal 和 metadata 的情况，我们只能使用 unix io。

标准 io：使用磁盘文件和 terminal 文件（eg：屏幕）的时候。

raw unix io：signal；对需求很清楚，需要最高性能的时候。

rio：在网络的时候可以使用。

接下来我们进入新的章节：网络

网络是一个非常复杂的方向，有专门可以研究的内容。我们只需要能用，了解基本结构就行了。

我们先介绍 client-server 变成模型。还有 p2p 模式。

像我们平时访问的 web 就是 cs。手机的小程序、ftp 都是这种。cs 是当前最主流的网络编程模式。client 是访问资源的人，server 就是掌握资源的人。有很多 client 寻求 server 的帮助。在单机里，也可以看作一种 cs 模式。server 就是 os，像操作系统发送请求。向屏幕发送请求进行打印，其实也是一种 cs 模式。client 和 server 都是进程，需要跑在那里。server 和 client 会约定好按照某种格式进行交互，以 request 进行传递。request 可以限定一些接口，

超出了限制的范围，server 就不会管了。因为约定好了 interface，client 和 server 就是松耦合，可以自己进行优化。只有满足约定的 request，server 才接收。

首先网络从硬件上来说是 io 的一部分，既可以 input 和 output。机器上插的叫做网卡（network adapter）

我们先要介绍网络。首先网络是一个层级结构，数亿机器设备都接入网络。要管理这些设备，要用层次化的方式来组织，像一棵树一样。box（终端设备）、wire（网线、或者无线信号）

网络越往下越 low level，最低层级的是 lan（loval area network）。lan 可以认为是网络里面很小的一块，一般按照 building 或者校园为单位。

网络里要用一个机器都懂的语言沟通在一块。在 lan 里面用的比较多的就是有线以太网（ethernet），使用以太网卡。lan 最底层就是一些 host（包括机器、手机、主机）。hub 就是把 host 连在一起的设备。hub 提供的口就叫做 port。hub 的一个特征就是广播的方法，当收到一个 request 的时候，就会广播给连在上面的所有 host。但是这个方式是不可扩展的，如果数百台机器连在上面，有效消息只有百分之一，机器自己都处理不过来。每个插上以太网的设备都会有一个 48 位的以太网 mac 地址。每一位都会有不同的含义，代表硬件的厂家等。发送的单位叫做 frame。

2021/04/13

将 network adapter 连在一块，就称为网络。而且是分层的架构，像金字塔一样构建在一块。粗略的划分是 lan 和 wan，在不同场景下可能称为不同的，只是一个粗略的概念。只是在网络发展初期的时候进行区分。现在有移动设备、手表等让这个结构更加的复杂了。

上节课介绍了 lan 最底层的是用 hub 进行连接的，缺点就是连接在上面的机器（host）数量不能很多。Host 过滤的方式：要有每个机器的唯一标识符，这个标识是对应了机器的 adapter 上的。每个 adapter 有 48 位的唯一标识符。虚拟机的网卡也会有 mac 地址。传输的叫做帧，也就是数据单位。

一个消息（message）包含了两部分，一部分是本身的内容（照片、文字等），叫做 payload。还有一部分是发送的对象、邮编等，这叫做 header。Header 和 payload 放在一起称作 frame，发出去。传输过程中关心的是 header，接受者关心的是 payload。

在整个建筑、校园中，都采用 hub 连接是不现实的。在其之上是一些更加智能的链接。越往上链接的是越高层的一些概念。在 hub 上有 bridge 的概念，需要根据消息的 header 的消息发送给某个 hub。

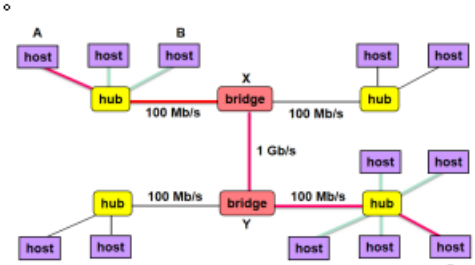

Bridge 比 hub 更聪明，知道应该把消息发送给哪个 host。Bridge 比 hub 更高层、功能更强、设备更复杂。

现在家里的 hub 也比较复杂，有线电视、有线网、无线网都集成在一块儿。所以现在 bridge 也越来越少，一部分功能去了 hub，一部分去了上面。所以，我们可以做以下简化，接在了一根逻辑的网络线上，都是使用相似的协议了。

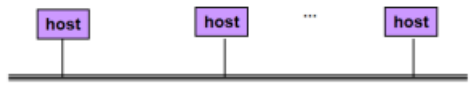

这里就牵涉到协议的一个概念，比如无线网和有线网使用的协议是完全不同的。不同的协议可以理解为是不同的国家里的人说不同的话。Bridge 可以认为是在一个国家内的链接。如果要把不同国家连在一起，就要对不同语言的协议做翻译。协议包括怎么写 header，怎么写发送的对象。在不同协议之间的翻译者（跨协议的网络链接）叫做路由器。

LAN 1 and LAN 2 might be completely different, totally incompatible LANs (e.g. Ethernet, Wifi, DSL (Digital Subscriber Line))

通过路由器（router）链接不同协议的网络。路由的能力很强，可以把不同协议的消息进行互通。路由器中可以加入防火墙、检查等功能。

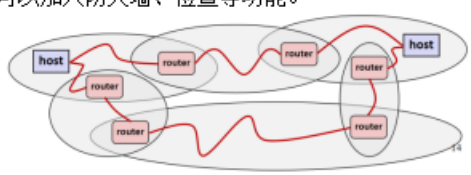

每个小的都可以有路由器进行连接，在这之间传递的就是 package（网络包）。前面提到的协议（protocol），一套协议可以认为是文字记录的表达规范。在计算机里需要由软件实现这一套协议，要发送的时候，OS 中嵌入了协议软件，来包装我们的 payload，包装成一个 package。网络各种协议的设计也称为网络栈，每一层完成一些网络。

TCP/IP 是两个不同层的协议来构成的，分别是 TCP 协议和 IP 协议。

接下来我们要介绍对应的协议。协议栈分很多层，有些层比较底层，规定了硬件的行为。程序员主要需要理解的是 TCP/IP 这两个层。网络层一个重要的行为就是取名策略。名字在网络中很重要，需要能够在整个网络中被识别到。Naming 具体的实现比较复杂，要尽可能保证唯一性。所以这是全局情况下 IP 对应的协议，统一对所有 host 给出一个唯一的地址。

在其之上的一层协议是 deliver 机制。完成命名了之后，就负责发送 package。要确定投递的方式等。TCP 就属于这一层。有了这个协议以后，如何从一台机器向另一台消息发送消息呢？

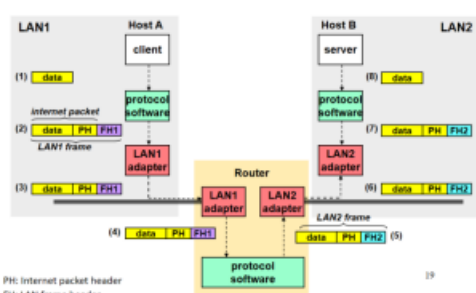

Data 在网络上传递的时候，只是一串 01 数据。客户端如何产生，服务器如何解读都和网络没关系。Host 发送时，需要网卡的帮助。所以需要操作系统来管理。通过对应的 syscall，把这个消息交给 kernel。操作系统中有对应的协议栈，根据网卡的信息，来选择合适的 protocol，对 data 加上 header。Header 包含两部分，一个是 host 级别上的（Internet packet

header），一个是 lan 级别上的 header（LAN frame header）。操作系统类似于给我们的信件加上了信封，然后帮我们向网络中投递出去。对应的封装是层次化的封装，换句话说，可能套了几层信封，在同样层中打开相应的信封。层次化包装的概念在网络中非常重要，使得我们的网络包非常适合网络这种层级结构。

Router 能够识别 FH1，router 负责翻译成对面认识的 header（换一个信封）。在 router 层级，只有蓝色和紫色是 header，里面黄色的都认为是 payload。传递到 LAN2 以后，就逐层地拆信封，最终取出 data，交给上层的应用程序。

整个网络是逻辑抽象的，可能向室友发送消息的包要走一圈才能回来。所以这是 virtual 和 physical 的一个对应关系。

Other issues

- We are glossing over a number of important questions:
  - What if different networks have different maximum frame sizes? (segmentation)
  - How do routers know where to forward frames?
  - How are routers informed when the network topology changes?
  - What if packets get lost?

对于过大的文件，需要切割，分片后可能走不同的路径，最终如何组装起来？路由器怎么找到最近的路？如果发送的多个包有一个丢了怎么办？

互联网中，90%收到的协议都和以下介绍的协议相关的。

IP 是基于 naming 的一套协议（全球 Internet 网）。首先介绍网络栈的概念，我们要分层地去实现一个网络协议。标准组织的 OSI 模型，七层架构。

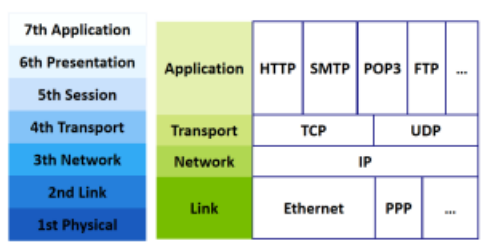

TCP/IP 是现在所用的一个事实标准（最后剩存下来，大家都按照这个方式来做）。事实标准比 OSI 简化的多。TCP/IP 分别对应了网络层和传输层。

IP 层主要为上层提供定位功能。上面传输层的 TCP 构建一个稳定的通路，在两个 host 之间构建一个逻辑上的通路。在这之间如果出现了网络上的丢包，TCP 是会帮你解决的。对应的 UDP 就是不可靠的，为了更快地发送到对面，如果有丢包，也会向上把信息传递给应用程度，速度很快，比如在一个数据中心的内部，网络比较稳定，就可以用 UDP 来加速数据传输。

接下来我们要介绍 Berkeley socket interface，这其实是一套网络 IO 对应的接口封装，和 protocol software 对接，是 syscall 的一套 lib 包装。它的优点是把网络抽象成了文件和 linux IO

兼容。

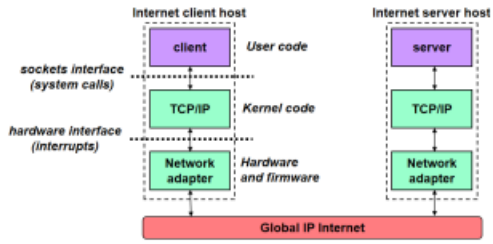

上图紫色的就是网络应用程序，要使用网络的时候，就需要使用 socket 进入 syscall，用 kernel 中的 TCP/IP 软件栈来负责加上 header，再给到网卡。

IP 最早的时候，是一个 32 位整数来代表。为什么会变成 IPV4 呢？这就牵涉到 32 位如何进行转化。比如说 ip 映射到域名。域名也是一个层级结构，从前往后从具体到高层。Ip 地址和域名之间有一个对应关系。每一个链接就是客户端和服务器之间要建立一个 connection。

我们发现 32 位的 IP 地址和域名是没有关系的，同时服务器还可能会搬动。这是需要一张表来记忆的。Ipv4：我们把 32 位分成四段，每一段都是 0 到 255，是可以直接翻译的。

- IP address 0xca7828bc = 202.120.40.188

```
/* Internet address structure */
struct in_addr {
   uint32_t s_addr; /* network byte order (big-endian) */
};
```

要特别强调的是，网络地址传输的时候是 big-endian 的。换句话说 IP 地址是要进行转化的。对应的翻译过程就是以下这些函数，h 代表 host，n 代表 network。即从 host 到 network 的转换。32 位是用来转 ip 地址的，16 位是用来转化 host（端口号）的。

- the following functions convert between network and host byte order
- No equivalent function for 64-bit value

```
#include <arpa/inet.h>

uint32_t htonl(uint32_t hostlong);
uint16_t htons(uint16_t hostshort);
          Returns: value in network byte order

uint32_t ntohl(uint32_t netlong);
uint16_t ntohs(uint16_t netshort);
              Returns: value in host byte order
```

- **inet_pton**: converts a dotted decimal string to an IP address in network byte order.
- **inet_ntop**: converts an IP address in network by order to its corresponding dotted decimal string.
- "**n**" denotes network representation, "**p**" denotes presentation.

需要有一个把域名和 IP 的映射关系存下来的地方。即 DNS 服务器（域名服务器，domain naming system）。网络程序和域名服务器联系，在本机上把域名转化为 ip 地址，有了 ip 地址才能在网络上发包。如果连不上域名服务器，不能把域名转化为 IP。那么可能访问 ip 可以直接访问，但是通过域名就不能访问。域名服务器就是存了一张很大的表，进行域名到 ip 的翻译。比较多的是一对一映射（1-1）。也可以一个域名对应对个 ip 地址（M-1），因为

服务比较大、比较重要，就可以通过服务分发的时候，把任务分发到不同的服务器。域名可能不对应任何 IP 地址(1-？)。

Localhost 可以模拟是一台机器，可以完全通过网络这条路进行链接，其实就是自己。

这里有一个概念叫做 Internet connection，两个 host 之间发消息，要先建立链接，再在这个链接之上发消息。这个动作是要在网络刚开始的时候要去做的。这个默认的链接就是 socket，其由两个部分组成，ip address 和 port。很多进程要使用一块网卡来发送/接收消息。消息到底发给哪个进程，需要进行一个细分，不同的服务进程可以占用不同的端口号。发送的对象具体到一个地址+一个 port。

Ip 地址和 port 都是有限的。Port 要建立一些划分的，有一些广泛认知的 port 对应了一些基础的协议。不同机器必须使用同一个 port，叫做 ephemeral port。比较有名的 port 号就是 80，如果是 http://就对应了 80 端口。Smtp 和 ftp 也有固定的 port 号。

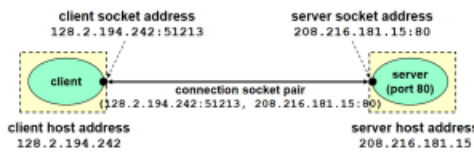

可以把这个 socket pair 抽象成一个文件。

我们回顾一下 CS 架构：

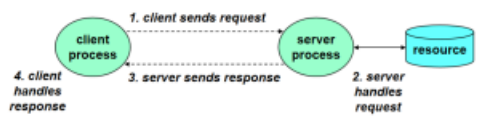

服务器通过客户端的请求返回响应的消息。游览器就是客户端的一个进程。Nginx 就是服务器端的一个 web server。IP(32 位)和 port(16 位)构成了一个唯一标识。客户端和服务器就是按照这一套协议进行交互的。游览器就是 http client，只是把收到的东西美化了出来。在 server 端，有 daemons（守护进程）。Server 是 7*24 等待 client 来连接的。当机器开机的时候，就会把这个机器所要提供的服务运行起来。提供 init 写一些脚本把服务开起来。

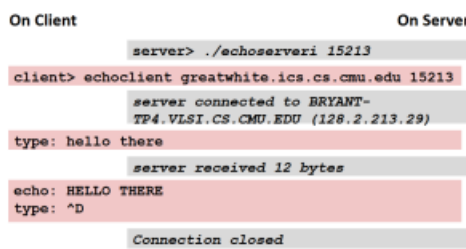

Echo server 就像是一个应答器。Client 说什么，server 就会回复什么（经过网络）。打开回声服务器，指定端口打开。echoclient 先去连这个 echoserver，建立完成链接以后。对于 echo protocol 协议，就是收到什么返回什么。

2021/4/20

今天我们介绍网络相关的一些编程接口，并且以这些接口为反例，实现一个简单的 Client-Server 的程序。这个程序我们之前见过，就是 echo server，在我们这个程序里需要经过网络。client 读取输入，通过网络发送到 server 端，server 再 echo 一个返回。我们来看这样的一个程序这么构建，肯定有一个 library。在网络下面，这个 library 就是 socket，有点像

unix I/O，也是一个建立在系统调用上的库。

首先我们简单了解一下 socket，这个词翻译成套接字。它最早是伯克利在自己的操作系统中使用的一套库，经过一段时间以后，它成为了一个事实上的使用的一套库。大量网络编程的库，都是基于 socket 之上的。它的一个很重要的特点就是“协议独立性”，我们知道在网络里有很多不同的协议，在不同的层里。在 TCP/IP 之上有应用层，在核里面封装的就是不同的协议。在层里有不同协议的层的实现。socket 提供了一个相同的接口来包装下层不同协议的实现，优点等于给不同的协议提供了一个一致的接口。所以我们只要使用一套库就行了。它是在 user level 的 library。

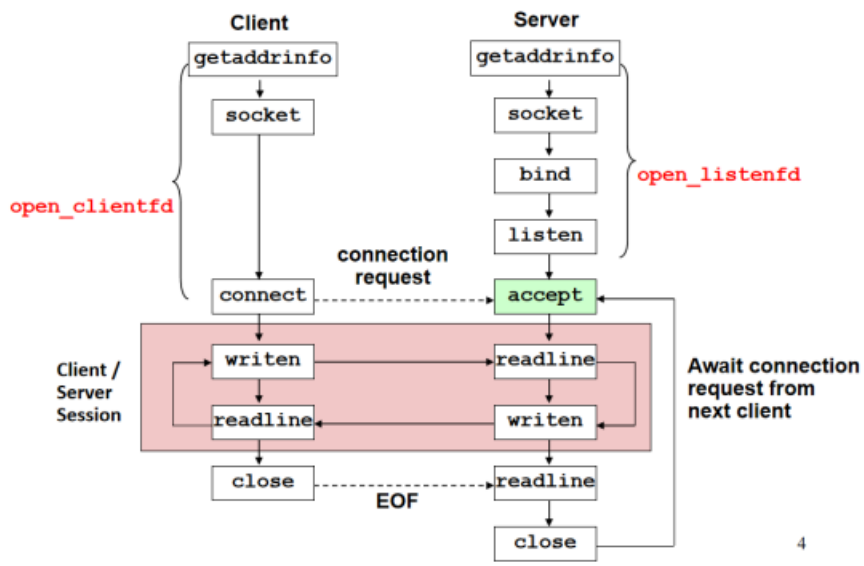

这个图描述了整个网络里面会涉及到的最主要的功能，左右两条线是客户端、服务器上的流程。

前面这个阶段是准备阶段，我们可以看到准备阶段上客户端和服务器要做的事情是不一样的。在 client 要去打开一个和 server 的链接，对于打开的网络链接抽象成文件，也是得到一个 fd，我们包装成 open_clientfd。服务器端，要起一个服务器，然后去等待请求。两端都对应了一个 IP 地址+端口。在 client 和 server 建立联系的时候，要分别提供对应的 ip+port，

红色部分就是完成连接以后进行的通讯。任何一端只有两个操作，读和写。需要约定好，发过去对面要及时接收。这也是 TCP/IP 等协议需要提供的一个数据传输的约定。再简单的服务之间也会有一套协议，比如我们的 echo server 也有这个协议。比如 client 发送一行等待 server 响应，server 回一句消息，期间不收新的消息。协议还会规定消息里面的格式，以及发送具体的内容。我们今天讲完以后，会重点讲 http 协议。我们会发现命令行的 http 协议和游览器看到的 http 的结果是完全不一样的，之后我们要自己去实现对 http 协议的处理。

C/S 会话结束了以后，client 就关闭了。但是 server 端要有一个循环到上面，因为我们的 client 会随时发给 server 一个请求。所以 server 端一直会有这个进程（叫做 daemon process，守护进程），等待新的请求。这里有个绿色的函数 accept，有点像 waitpid 函数的行为，它是要等待 client 连接，如果没有 client 就会一直等下去。

socket 想尽量把文件 IO 和网络 IO 统一在一块。socket descriptor 和 fd 的含义差不多，让应用程序做对应的读写。CS 都能在连接上进行读写的，叫做双工。有些单向的只能往里面写或者读。

socket 的打开方式，不仅和文件的打开不同，CS 两端的 socket 打开也不同。socket 返回的是 sockaddr，第一个是 family 告诉你，返回的是哪个协议簇（协议家族），比如 TCP/IP 等。下面的是 32 位的地址和 port。还有 sin_zero[8]是填充的。

通用的 sockaddr 最多有 14 个 byte 的地址。

可以用 C 语言把通用的 sockaddr 转化为 sockaddr_in（TCP/IP 使用的 IP 地址，只使用了 6 个 byte，剩下的 8 个 byte 是空的）

```
1   #include "csapp.h"
2
3   int main(int argc, char **argv)
4   {
5       struct addrinfo *p, *listp, hints;
6       char buf[MAXLINE];
7       int rc, flags;
8
9       if (argc != 2) {
10          fprintf(stderr, "usage: %s <domain name>\n", argv[0]);
11          exit(0);
12      }
13
14      /* Get a list of addrinfo records */
15      memset(&hints, 0, sizeof(struct addrinfo));
16      hints.ai_family = AF_INET; /* IPv4 only */
17      hints.ai_socktype = SOCK_STREAM; /* Connections only */
18      if ((rc = getaddrinfo(argv[1], NULL, &hints, &listp)) != 0) {
19          fprintf(stderr, "getaddrinfo error: %s\n", gai_strerror(rc));
20          exit(1);
21      }
```

下面，我们首先介绍两个函数，一个是 getaddrinfo 和 getnameinfo。我们需要先从域名从 DNS 查到对应的 address。也就是输入一个域名，返回的是一个 address 的 list。有了 IP 地址，就可以提供给 socket 来建立连接。server 端可以调用 getnameinfo，从客户端的 IP 反推出域名或者 hostname。

2021/4/25

网络牵涉到发射方和接收方，需要有约定获取数据的步骤和格式。在 client socket 我们介绍 http 协议。Web client 向 web server 发送请求，webserver 负责返回网页（包括静态网页和动态网页）。动态网页是根据不同人的请求返回不同的网页。

我们需要了解简单的 http 协议，然后看一下支持这个 http 协议的 web server（可以接受不同的 web 请求，使用不同的游览器都可以连这个 web server）怎么实现。http 协议就是请求网页，协议本身的基础部分很简单，只是约定了发送出去的格式或者接受的格式。这边展示的是 client 向 server 发出请求的格式。Web client 只需要构建一个连接，然后向 server 请求，得到一个返回。

```
//Client: open connection to server
unix> telnet ipads.se.sjtu.edu.cn 80
//Telnet prints 3 lines to the terminal
Trying 202.120.40.88...
Connected to ipads.se.sjtu.edu.cn.
Escape character is '^]'.
//Client: request line
GET /courses/ics/index.shtml HTTP/1.1
//Client: required HTTP/1.1 HOST header
host: ipads.se.sjtu.edu.cn
//Client: empty line terminates headers
```

首先用 telnet 构建一个连接，无非就是告诉它域名和端口。这个和 echo client 所做的事情差不多。蓝色部分是 telnet 的一些输出（其调用 getaddrinfo 拿到域名所对应地址），告诉你建立已经成功了，然后等待你的输入（按 ctrl+c 输入）。

后面两行是你输出的一些请求，发送到 web server 端，webserver 会按照规则来解析你的请求。第一个是个 GET 操作，后面是请求的网页的路径（是 server name 的路径），你所打的网址也就是前面一段是建立连接的，后面一段是找资源的。然后是 HTTP 的 1.1 版本。下面是一些辅助信息，叫做 headers。对于初级的 http 协议，不支持对 header 的处理，这些直接丢弃。这个命令很简单，就是向 web server 要一个静态网页。

- HTTP request is a request line, followed by zero or more request headers

- Request line: <method> <uri> <version>
  - <version> is HTTP version of request (HTTP/1.0 or HTTP/1.1)
  - <uri> is typically URL for proxies, URL suffix for servers.
    - A URL is a type of URI (Uniform Resource Identifier)
    - See http://www.ietf.org/rfc/rfc2396.txt
  - <method> is either GET, POST, OPTIONS, HEAD, PUT, DELETE, or TRACE.

这是 http 里对请求的约定，一个是 request 部分，下面可以有多行的 request headers。Request 包含三个部分，由空格隔开。Method 最简单的是 get 操作，然后是网页的路径，然后是协议的版本。我们的 tiny web server 也只支持这一种请求。

Get 和 Post 都是最基本的取网页，大部分请求都是 GET 请求，POST 请求可以把数据包含在请求里面，往往是提交一些表单等。

Request header 相当于环境变量，可以用 header name: header data 的格式。

```
//Server: response line
HTTP/1.1 200 OK
//Server: followed by five response headers
Server: nginx/1.0.4
Date: Thu, 29 Nov 2012 10:15:38 GMT
//Server: expect HTML in the response body
Content-Type: text/html
//Server: expect 11,560 bytes in the resp body
Content-Length: 11560
//Server: empty line ("\r\n") terminates hdrs
```

请求的返回是一个字符串流，相当于收到一封回信一样。它会有一个头，头部告诉你返回是正确的，比如响应码是 200。下面会带一些像 header 一样的状态信息，可以根据这个 header 做一些操作，或者直接忽略掉。

- HTTP response is a response line followed by zero or more response headers.
- Response line: `<version> <status code> <status msg>`
  - `<version>` is HTTP version of the response.
  - `<status code>` is numeric status.
  - `<status msg>` is corresponding English text.

200 OK	Request was handled without error
301 Moved	Provide alternate URL
403 Forbidden	Server lacks permission to access file
404 Not found	Server couldn't find the file
501 Not Implemented	Server does not support the request method
505 HTTP version not supported	Server does not support version in request

- Response headers: `<header name>: <header data>`
  - Provide additional information about response
  - `Content-Type:` MIME type of content in response body
  - `Content-Length:` Length of content in response body

响应 header 的最有用的信息就是 Conetent-Type 和 Content-Length。我们 web client 就会从 web server 拿到文本格式的 html 页，因为我们没有渲染功能。我们下面更多地关注 web server 怎么去实现。

- Client sends request to server
- If request URI contains the string "/cgi-bin", then the server assumes that the request is for dynamic content.

- The server creates a child process and runs the program identified by the URI in that process

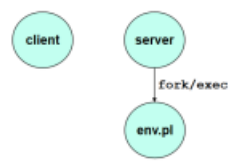

大家通常约定动态网页放在 cgi-bin 目录里面。

正常情况下，server 会通过 fork 出一个子进程，然后传入参数执行。把执行完的结果，通过 server 返回给 client。

对于动态网页的来说，还存在一些问题我们不知道怎么去回答。一个是参数怎么传给 server，第二个是 server 怎么把参数传递给子进程，当然可以自己构建出 argc 和 argv，然后 execve 的时候自动传入参数，但是这不是很灵活。第三个问题，就是子进程怎么把参数返回给 server，server 还要再去还给 client。这些是通过 CGI（common gateway interface）规范来定义的。

第一件事情，是怎么从 client 向 server 传递参数。因为只接受字符串，要把参数编码进字符串里面。<可执行文件名>?参数 1&参数 2…… 为什么游览器里的空格都会被转化为%20 呢？因为字符串里不能有空格，否则后面的 URL 就被解析为下一个参数了。

第二件事情，怎么把参数传递给 fork 出来的子进程？这里采用了一个环境变量的形式，所有把我所有的参数都拷贝给 QUERY_STRING，QUERY_STRING 后面的解析就交给被调用的子进程去解析。

```
if ((buf = getenv("QUERY_STRING")) != NULL) {
      p = strchr(buf, '&');
      *p = '\0';
      strcpy(arg1, buf);
      strcpy(arg2, p+1);
      n1 = atoi(arg1);
      n2 = atoi(arg2);
}
```

如果程序是被网络调用的，是个标准的 web cgi 程序的话，会解析这个环境变量。此外还有一些其他的信息，也是通过环境变量的方式，只是环境变量的名字修改了。

- Request-specific
  - QUERY_STRING (contains GET args)
  - SERVER_PORT
  - REQUEST_METHOD (GET, POST, etc)
  - REMOTE_HOST (domain name of client)
  - REMOTE_ADDR (IP address of client)
  - CONTENT_TYPE (for POST, MIME type of the request body)
  - CONTENT_LENGTH (for POST, length in bytes)

如果我们需要这些信息，我们可以在 CGI 程序中进行解析。之前是直接把?之后的进行截断，然后赋给 QUERY_STRING，只需要按照一个规定动作来做，让 Server 做的事情变少，这样就能尽可能支持了可扩展性（server 的主题所做的事情尽可能要少）。

第三件事情，子进程如何返回值，我们知道子进程返回给 server，server 再返回给 client 是不可扩展的。因为可能同时一百个子进程返回，导致数据流都集中在 server 上，使得可扩展性变低。CGI 程序根本不需要把返回值传递给 Server，只要让 server 把 connectfd 传递给子进程。事实上子进程是复制了一份 connectfd，子进程可以直接把结果返回给 client，直接和 client 联系，这样 server 不会成为一个性能的瓶颈。对于 child 来说，采用了重定向的方式。Server 在 fork 子进程之前，子进程会默认打开三个文件（标准输出/输入/错误输出），在 fork 前，把 connectfd dup 成标准输出。子进程是不会使用 stdout 的，只要默认的使用 printf 打印，会被重定向到 connectfd 上。这样的好处是直接地在 server 端看到结果，全部调试完了以后，再重定向到 connectfd 上即可。

下面，我们介绍 tiny web server 的简单实现，它只支持文本格式和 GET 命令，功能比较完整。Web server 无非就是解析 request，先判断是否是动态的还是静态的。如果是静态的，就创建 CGI 子进程，为其准备好参数，帮其重定向好标准输出。

```
16 int main(int argc, char **argv)
17 {
18     int listenfd, connfd;
19     char hostname[MAXLINE], port[MAXLINE];
20     socklen_t clientlen;
21     struct sockaddr_storage clientaddr;
22
23     /* check command line args */
24     if (argc != 2) {
25         fprintf(stderr,"usage: %s <port>\n", argv [0]);
26         exit(1);
27     }
28
29     listenfd = open_listenfd(argv[1]);
30     while (1) {
31         clientlen = sizeof(clientaddr);
32         connfd = Accept(listenfd, (SA *)&clientaddr, &clientlen);
33         Getnameinfo((SA*)&clientaddr, clientlen, hostname, MAXLINE,
34                     port, MAXLINE, 0)
35         printf("Accepted Connection from (%s, %s)\n", hostname, port);
36         doit(connfd);
37         Close(connfd);
38     }
39 }
```

Main 函数上来，server 要启动，指定一个 port。拿到 port 以后用 openlistenfd 启动。主

体函数和原来的 echo server 是差不多的。Session 结束一个 close（connfd）。差别只是在 doit 函数上。

```
9       /* Read request line and headers */
10      Rio_readinitb(&rio, fd);
11      Rio_readlineb(&rio, buf, MAXLINE);
12      printf("Request headers:\n");
13      printf("%s", buf);
14      sscanf(buf, "%s %s %s", method, uri, version);
15      if (strcasecmp(method, "GET")) {
16              clienterror(fd, method, "501", "Not implemented",
17                      "Tiny does not implement this method");
18              return;
19      }
20      read_requesthdrs(&rio);
21
```

```
22      /* Parse URI from GET request */
23      is_static = parse_uri(uri, filename, cgiargs);
24      if (stat(filename, &sbuf) < 0) {
25              clienterror(fd, filename, "404", "Not found",
26                      "Tiny couldn't find this file");
27              return;
28      }
29
30      if (is_static) { /* Serve static content */
31              if (!(S_ISREG(sbuf.st_mode)) || !(S_IRUSR & sbuf.st_mode)) {
32                      clienterror(fd, filename, "403", "Forbidden",
33                              "Tiny couldn't read the file");
34                      return;
35              }
36              serve_static(fd, filename, sbuf.st_size);
37      }
```

用 robust-io 来初始化。可以读到 method、uri 和 version。解析完先检查 method 是不是 get。这是一个网络请求，不管对错都应该返回一个 http response，所以我们要返回一个带有出错信息的 response（用 clienterror 函数）。下面会调用 read_requesthdrs(&rio);来处理 header，不读是不行的，因为这些东西还在网络上，我们这里读完直接扔掉就可以了。根据读到的 uri 来判断是静态的还是动态的，也就是判断有没有 cgi-bin 目录。如果没有找到文件，就返回 404。

静态这边就是要确定找到并且文件有对应的 user 可读权限。过了这个检查以后调用了 serve_static 传入文件名，文件大小传进去。

对于动态的，要求的就是可执行文件的执行文件，因为它所要的是程序执行的结果。采用一次连接只返回一个 response 的方式，可以服务更多的人。具体我们来看函数的具体实现。

```
1  void clienterror(int fd, char *cause, char *errnum,
2                   char *shortmsg, char *longmsg)
3  {
4      char buf[MAXLINE], body[MAXBUF];
5
6      /* build the HTTP response body */
7      sprintf(body, "<html><title>Tiny Error</title>");
8      sprintf(body, "%s<body bgcolor=""ffffff"">\r\n", body);
9      sprintf(body, "%s%s: %s\r\n", body, errnum, shortmsg);
10     sprintf(body, "%s<p>%s: %s\r\n", body, longmsg, cause);
11     sprintf(body, "%s<hr><em>Tiny Web server</em>\r\n",body);
12
13     /* print the HTTP response */
14     sprintf(buf, "HTTP/1.0 %s %s\r\n", errnum, shortmsg);
15     Rio_writen(fd, buf, strlen(buf));
16     sprintf(buf, "Content-type: text/html\r\n");
17     Rio_writen(fd, buf, strlen(buf));
18     sprintf(buf, "Content-length: %d\r\n\r\n", strlen(body));
19     Rio_writen(fd, buf, strlen(buf));
20     Rio_writen(fd, body, strlen(body));
21 }
```

这是出错的实现，参数是原因，error member。返回 http version 然后是 error message。长度就是 body 的长度。先发 header 部分，再发 body 部分。

```
1 void read_requesthdrs(rio_t *rp)
2 {
3         char buf[MAXLINE];
4
5         Rio_readline(rp, buf, MAXLINE);
6         while(strcmp(buf, "\r\n")){
7             Rio_readlineb(rp, buf, MAXLINE);
8             printf("%s", buf);
9         }
10        return;
11 }
```

循环读 header，读到一个空行为止，表示请求结束了。这里是直接把 header 丢掉。

```
1   int parse_uri(char *uri, char *filename, char *cgiargs)
2   {
3       char *ptr;
4
5       if (!strstr(uri, "cgi-bin")) { /* static content */
6               strcpy(cgiargs, "");
7               strcpy(filename, ".");
8               strcat(filename, uri);
9               if (uri[strlen(uri)-1] == '/')
10                  strcat(filename, "home.html");
11              return 1;
12      }
13      else { /* dynamic content */
14              ptr = index(uri, '?');
15              if (ptr) {
16                  strcpy(cgiargs, ptr+1);
17                  *ptr = '\0';
18              } else
20                  strcpy(cgiargs, "");
21              strcpy(filename, ".");
22              strcat(filename, uri);
23              return 0;
24      }
25  }
```

是否包含 cgi-bin，如果包含就是动态的，否则就是静态的。路径是 web server 管理的子目录的路径，所以要在原来的 url 的相对路径的基础上，最前面加一个点，代表是当前目录的相对路径。静态的话，默认使用 home.html；动态的话，如果有?的话，把?后面全部截下来作为参数，传给 CGI 去解决。

```
1   void serve_static(int fd, char *filename, int filesize)
2   {
3       int srcfd;
4       char *srcp, ftype[MAXLINE], buf[MAXBUF];
5
6       /* send response headers to client */
7       get_filetype(filename, ftype);
8       sprintf(buf, "HTTP/1.0 200 OK\r\n");
9       sprintf(buf, "%sServer: Tiny Web Server\r\n", buf);
10      sprintf(buf, "%sConnection: close\r\n", buf);
11      sprintf(buf, "%sContent-length: %d\n", buf, filesize);
12      sprintf(buf, "%sContent-type: %s\r\n\r\n", buf, ftype);
13      Rio_writen(fd, buf, strlen(buf));
14      printf("Response headers:\n");
15      printf("%s", buf);
16
17      /* send response body to client */
18      srcfd = Open(filename, O_RDONLY, 0);
19      srcp = Mmap(0,filesize,PROT_READ,MAP_PRIVATE,srcfd,0);
20      Close(srcfd);
21      Rio_writen(fd, srcp, filesize);
22      Munmap(srcp, filesize);
23  }
```

```
25  /*
26  * get_filetype - derive file type from file name
27  */
28  void get_filetype(char *filename, char *filetype)
29  {
30      if (strstr(filename, ".html"))
31          strcpy(filetype, "text/html");
32      else if (strstr(filename, ".gif"))
33          strcpy(filetype, "image/gif");
34      else if (strstr(filename, ".png"))
35          strcpy(filetype, "image/png");
36      else if (strstr(filename, ".jpg"))
37          strcpy(filetype, "image/jpg");
38      else
39          strcpy(filetype, "text/plain");
40  }
```

对于静态网页的处理，我们已经判断过这个存在并有权限，我们只需要把这个文件嵌入到返回的 body 即可，不需要读文件了。我们也要构造响应的访问 header。比如关闭 connection，如果要再访问的话要重新建立连接。可以通过 get_filetype 来获取文件类型。

Mmap 可以把一个文件直接映射到内存空间，把映射得到的内存地址直接作为网络包发送出去。

get_filetype 里面，凡是不认识的，都作为 text/plain 发送。

```
1  void serve_dynamic(int fd, char *filename, char *cgiargs)
2  {
3      char buf[MAXLINE];
4
5      /* return first part of HTTP response */
6      sprintf(buf, "HTTP/1.0 200 OK\r\n");
7      Rio_writen(fd, buf, strlen(buf));
8      sprintf(buf, "Server: Tiny Web Server\r\n\r\n");
9      Rio_writen(fd, buf, strlen(buf));
10
11     if (Fork() == 0) { /* child */
12         /* real server would set all CGI vars here */
13         setenv("QUERY_STRING", cgiargs, 1);
14         Dup2(fd, STDOUT_FILENO); /* redirect output to client*/
15         Execve(filename, NULL, environ); /* run CGI program */
16     }
17     Wait(NULL); /* parent reaps child */
18 }
```

动态的处理，我们关注创建子进程执行文件的部分。这牵涉到 header 部分谁来返回。我们发现 header 的前面两行是由 server 来返回的，下面的子进程返回的只有 Content-length 和 Content-type 以及 body 部分。在执行之前，我们要传参数进 QUERY_STRING，并且用 connectfd 来重定向标准输出，把标准输出替换为 client 端的链接。

Proxies

- A proxy is an intermediary between a client and an origin server.
  - To the client, the proxy acts like a server.
  - To the server, the proxy acts like a client.

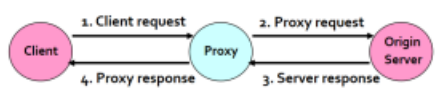

下面我们要介绍第九个 lab 的内容，这个 proxy 是一个网络程序。它是介于 client 和 server 之间的。对于客户端来说，它的请求发给 proxy，proxy 返回给它，proxy 就是一个服务器。对于服务器来说，它的请求发给 server，server 返回给他，proxy 就是一个客户端。所以，proxy 是同时需要有客户端和服务器的能力。

- Can perform useful functions as requests and responses pass by
  - Examples: Caching, logging, anonymization, filtering, transcoding

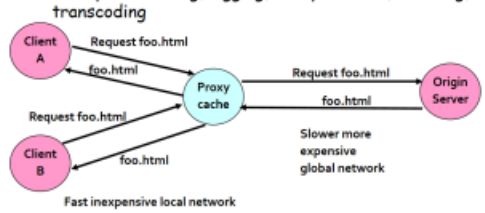

它有什么用呢？1.proxy 可以做 cache，第一次请求的时候发给 proxy，proxy 没有资源，proxy 向视频网站请求后，把资源返回，并在本地存一份。第二个请求来的时候，就不需要再去连接服务器了。这可以节省网络流量。2.proxy 可以记录 log，可以监视客户端请求，比如一个网络不允许打游戏。因为 proxy 是转发的东西，所以访问什么东西都可以知道。3.区域匿名化，有了 proxy 以后，服务器都只知道是 proxy，而不知道是谁。4.可以做一些过滤，返回的信息，如果有不良信息，proxy 可以过滤掉。网络上传递的数据可以分为 pay-load 和

header，禁掉的可能是 twitter 的 header。我们可以 header 里面去访问 proxy，proxy 接收到以后帮我们加上 twitter，就可以正常访问 twitter 了。

各种网络上的设备，比如防火墙什么都可以使用 proxy 实现。网络部分就介绍到这边，我们要关系的就是怎么用 socket 完成网络协议的实现，我们也介绍了 http 的 webserver 的实现。

第十二章：并发编程

这是一种能力，原来的程序可以写成并行的。比如 server 接受 client 请求，原来是串行的，如何变成并行的环境呢。我们的 OS 就是分时操作系统，一个程序的步骤之间可以进行并行，来获得更好的用户体验。

并发程序有多种，大家比较熟悉的是多进程的并发。我们之前说到后台运行的 console，可以通 fork 来完成多进程的并行。

我们要介绍进程、线程、和 I/O multiplexing（I/O 多路复用技术）这三种实现并行编程的方法。

硬件的 CPU 可以执行多个程序，也是并发。硬件会使用这种并行来提高响应。在我们之前的介绍里，我们介绍进程的 handler 的时候，我们有两个执行流（main 函数和 handler 存在同时执行的情况）。这个过程操作系统支持硬件来的一些中断，这个过程也是并行。我们关心的是大量的并行程序是怎么 work 的，有什么样的好处。

并行的好处：1.可以处理各种异步事件（你不知道什么时候回来，来的时候想抓紧时间处理掉，最好还不要影响程序的执行，eg：handler）2.希望支持多 CPU 的使用，一个程序跑在多个 CPU 上来利用更多的资源。3.解决一些异步设备（I/O 设备）读写比较慢的情况。4.和用户打交道的情况，因为人的输入比较慢，在人输入的时候希望做一些自己的事情。5.网络如果按部就班一个个处理，就不能解决多人的情况。操作系统定时地轮询不同的程序，进行分配。因为操作有快有慢，我们不希望慢的操作把快的操作挡住了。

自己实现比较困难，最好是操作系统提供了一个调度接口，让操作系统帮我们去实现调度。这种就叫做并发编程。

从进程到线程到 I/O 多路复用技术，越来越轻量级。但是这些并行都是应用程序层级的，比如我们希望一个 web server 实现同时和多个 client 去打交道。*concurrency 的程序实现起来比较困难，在实现的时候，要把自己的思考方式变成一个并行的程序，程序容易出错，比如调度的顺序不确定，光这一点就会引起很多的问题。比如，竞争问题，死锁问题，饥饿问题。